

Minería de textos georreferenciados aplicada al contexto de robos en Lima, Perú



**Universidad
Internacional
de Valencia**

Titulación:

Máster Universitario en Big Data
y Ciencia de Datos
Curso académico
2025 – 2026

Alumno:

Fernández Egúsquiza Alexander
Frei
D.N.I: 42453045
Directora de TFM: Huerta Pacheco
Nery Sofía

Convocatoria:

Tercera

De:

 Planeta Formación y Universidades

Índice

Resumen	4
Adstract.....	5
Capítulo 1: Introducción.....	6
1.1 Antecedentes	6
1.2 Planteamiento del problema.....	8
1.3 Objetivos.....	10
1.3.1 General.....	10
1.3.2 Específicos	10
1.4 Justificación	10
Capítulo 2: Estado del arte.....	12
2.1 Minería de datos.....	12
2.2 Minería de texto.....	18
2.3 Web scraping	19
2.4 Georreferenciación	21
2.5 Técnicas aplicadas para datos textuales	23
2.6 Otras herramientas para analizar datos textuales	24
2.7 Marco de referencia	25
Capítulo 3: Desarrollo del proyecto.....	27
3.1. Metodología.....	28
3.2 Descripción de los datos.....	32
Capítulo 4: Hallazgos encontrados	34
4.1. Extracción de datos	34
4.2. Análisis de los datos.....	34
4.2.1 Descripción.....	34
4.2.2 Agrupación de información	48
4.2.3 Análisis Espacial	51
4.2.4. Resultados de la Evaluación	54
Capítulo 5: Conclusiones	56
5.1. Conclusiones del trabajo.....	56
5.2. Limitaciones técnicas y oportunidades de mejora.....	57
5.3. Trabajos a futuro.....	58
5.4. Contribución a la investigación	59
Capítulo 6: Referencias	60
Capítulo 7: Anexos	63

Índice de Tablas

Tabla 1.1: Tasa de víctimas de robo o intento de robo (2020 a 2024).....	6
Tabla 2.1: Comparativo entre Minería de datos y Minería de textos	16
Tabla 3.1: Cantidad de noticias por año y por diario (2020–2024)	32
Tabla 4.1: Frecuencia de palabras asociadas a Robo (2020 a 2024).....	34
Tabla 4.2: Frecuencia de robos reportados por Distritos (2020 a 2024).....	35
Tabla 4.3: Frecuencia de palabras asociadas a Robo (2020 a 2021).....	37
Tabla 4.4: Frecuencia de robos reportados por Distritos (2020 a 2021).....	38

Índice de Figuras

Figura 1.1: Diferencias entre minería de datos y minería de texto.....	7
Figura 1.2: Flujo de trabajo: web scraping, clasificación de texto, generación de indicadores de innovación, almacenamiento y consulta	8
Figura 3.1: Etapas de la presentación del conocimiento	32
Figura 4.1: Gráfico de líneas de la distribución de noticias (2020 al 2024).....	40
Figura 4.2: Nube de palabras del contenido textual (2020 al 2024)	41
Figura 4.3: Nube de palabras del contenido textual (2020 al 2021)	42
Figura 4.4: Nube de palabras asociadas a Robo (2020 al 2024).....	43
Figura 4.5: Nube de palabras asociadas a Robo (2020 al 2021).....	43
Figura 4.6: Nube de palabras asociadas a Distritos (2020 al 2024)	44
Figura 4.7: Nube de palabras asociadas a Distritos (2020 al 2021)	45
Figura 4.8: Análisis de correspondencia (2020 a 2024)	46
Figura 4.9: Análisis de correspondencia (2020 a 2021)	47
Figura 4.10: Dendrograma de palabras asociadas a los Distritos (2020 a 2024)	48
Figura 4.11: Dendrograma de palabras asociadas a los Distritos (2020 a 2021)	49
Figura 4.12: Clusters identificados en dendrograma (2020 a 2024).....	51
Figura 4.13: Clusters identificados en dendrograma (2020 a 2021).....	52
Figura 4.14: Mapa de robos reportados en noticias web (2020 a 2024).....	53
Figura 4.15: Mapa de robos reportados en noticias web (2020 a 2021).....	54

Resumen

El presente trabajo integra la minería de textos, técnicas de *web scraping* y procesos de georreferenciación dentro del marco metodológico del Descubrimiento de Conocimiento en Bases de Datos (KDD), con el propósito de identificar patrones espacio-temporales asociados a noticias sobre robos ocurridos en Lima, Perú, durante el periodo 2020–2024. La metodología KDD permitió estructurar el proceso investigativo en fases secuenciales: selección, preprocesamiento, minería, evaluación y presentación; garantizando coherencia analítica y trazabilidad técnica desde la recolección de datos hasta la generación de conocimiento aplicable.

La base de datos fue construida mediante un *web scraping* aplicado a algunos diarios web de Lima, Perú: El Comercio, Gestión, Correo y Ojo, utilizando el lenguaje R, obteniéndose así un total de 32411 registros que contienen el título, resumen y fecha. Posteriormente, se desarrollaron procesos de limpieza semántica, normalización léxica, eliminación de *stopwords* y georreferenciación por distrito, asegurando consistencia textual y espacial para el análisis.

En coherencia con el marco metodológico del KDD, la fase de minería de datos y minería de textos constituyó el núcleo analítico del estudio, siendo el momento en el cual se aplicaron algoritmos y técnicas estadísticas para la identificación de patrones. Dentro de esta etapa se emplearon tablas de frecuencia, matrices de contingencia, análisis de correspondencias, análisis de *cluster* jerárquico representado mediante dendrogramas, así como visualizaciones complementarias mediante nubes de palabras y mapas temáticos. Esta implementación permitió transformar los datos textuales previamente depurados y georreferenciados en estructuras analíticas interpretables.

Los resultados obtenidos evidenciaron que los distritos con mayor incidencia relativa de noticias asociadas a robos durante el periodo 2020–2024 en Lima Metropolitana fueron: San Juan de Lurigancho, Miraflores, San Martín de Porres y Comas, mostrando así patrones espaciales persistentes y coherentes con la estructura urbana de Lima. Estos hallazgos demuestran la capacidad de la minería de textos georreferenciada para identificar zonas críticas a partir de información periodística digital, consolidando una metodología replicable para el análisis criminológico urbano y el apoyo a la toma de decisiones en seguridad ciudadana, no solo en Lima, sino en otras ciudades del Perú y del Mundo.

Palabras clave: minería de textos, *web scraping*, georreferenciación, análisis espacial, robos, KDD.

Abstract

The present study integrates text mining, web scraping techniques and georeferencing processes from the Knowledge Discovery in Databases (KDD) methodology in order to identify space-time patterns associated with assaults that occurred in Lima, Peru from 2020 to 2024. The methodology allowed to structure the research process in sequential phases: selection, preprocessing, mining, pattern evaluation and knowledge presentation; guaranteeing analysis coherence and technical traceability from data collection to applicable knowledge generation.

The database was built using web scraping techniques applied to the following newspapers: El Comercio, Gestion, Correo and Ojo, using R language, obtaining a total of 32 411 registries structured in title, summary and data. Afterwards, we developed processes of semantic cleaning, lexical normalization, stop words removing and by district georeferencing, assuring textual and spatial consistency for the analysis.

In accordance with the KDD methodology, the data mining and text mining phases constituted the study analytic core, at the moment in which algorithms and statistical techniques for trend patterns identification were used. In this step we employed frequency tables, contingency matrices, correspondence analysis, hierarchy *cluster* analysis with dendrograms, as well as complementary visualizations via word clouds and thematic maps. This implementation allowed us to transform previously refined and georeferenced text data into interpretable analytic structures, assuring that the discovery of spatial and thematic patterns would be done under a methodology flow consistent with established KDD phases.

Results showed that the districts with the highest assault related incidents during the 2020-2024 period in Metropolitan Lima were: San Juan de Lurigancho, Miraflores, San Martín de Porres y Comas, showing persistent spatial patterns in consistency with Lima urban structure. These discoveries demonstrate the capacity of georeferenced text mining to identify critical zones from digital press information, consolidating a replicable methodology for urban crime analysis and the urban security decision-making support, not only in Lima, but in other cities in Peru and around the world.

Keywords: text mining, web scraping, georeferencing, spatial analysis, robberies, KDD.

Capítulo 1: Introducción

1.1 Antecedentes

Hablar de robos en el Perú, es un tema debatido que ha venido de años. El presente trabajo, muestra un análisis de datos entre los años 2020 a 2024 en Lima Metropolitana, con el fin de ver la distribución de los delitos de robo, que se considera una problemática social. Durante los años 2020 a 2021, los robos disminuyeron notablemente debido a las restricciones de movilidad por la pandemia. A partir de 2022, con el retorno progresivo a la actividad presencial, los robos aumentaron progresivamente y se concentraron principalmente en robos personales en la vía pública. Los delitos que explican la mayor parte de la victimización son el robo de celulares, seguido del robo de dinero y carteras, generalmente sin uso de armas de fuego; y en menor proporción se presentan los robos de vehículos o autopartes. En 2024, aunque hay señales de ligera reducción en denuncias, el perfil delictivo sigue dominado por robos rápidos, oportunistas y de bajo monto, dirigidos a transeúntes mediante uso de motocicletas. A continuación, se muestra (ver Tabla 1.1) cómo ha variado la tasa de víctimas de robo o intento de robo (por cada 100 habitantes de 15 años y más) en Lima Metropolitana (Instituto Nacional de Estadística e Informática, 2024).

Tabla 1.1: Tasa de víctimas de robo o intento de robo (por cada 100 habitantes de 15 años a más) en Lima Metropolitana, enero 2020 – diciembre 2024

Año	Robo o intento de robo (total)	Variación vs. año anterior
2020	21.1	-
2021	14.9	-6.2
2022	18.9	4
2023	20.8	1.9
2024	19	-1.8

Nota. Adaptado de *Victimización en el Perú 2024* del Instituto Nacional de Estadística e Informática (INEI), 2024.

En el contexto referido, mediante la aplicación de herramientas como *web scraping* para la recolección de datos, se buscó apoyar al estudio de dicha problemática desde una perspectiva analítica, ya que está asociado a capturar y obtener datos de páginas web, generalmente utilizando técnicas automatizadas como *bots* o rastreadores web. Estos datos pueden ser utilizados para una variedad de aplicaciones, como la creación de

modelos de lenguaje para *chatbots* o el análisis de patrones y tendencias en la información publicada en la web.

La Minería de Texto, por su parte es una herramienta que se basa en el Procesamiento del Lenguaje Natural (PLN), el cual a su vez es parte de la Inteligencia Artificial (IA) y de la Minería de Datos; y se combinan con técnicas de *Machine Learning*. Esta herramienta en términos prácticos tiene como objetivo extraer información de alta calidad de grandes conjuntos de datos (*Big data*), como noticias, correos electrónicos o *tweets*, entre otros. Algunas aplicaciones típicas de minería de texto incluyen análisis de sentimientos, extracción de información y modelado de temas. He aquí algunas diferencias entre la Minería de Texto y la Minería de Datos (ver Figura 1.1).


Figura 1.1: *Diferencias entre minería de datos y minería de texto*



Nota. Adaptado de *Text Mining: Analyzing Unstructured Data*, por Project Guru (s.f.)

En resumen, el *web scraping* se utiliza para recolectar datos de sitios web, mientras que la minería de texto se utiliza para procesar y analizar esos datos, extrayendo información de alta calidad y descubriendo patrones y tendencias en la información. A continuación, se presenta en la Figura 1.2 el proceso de *web scraping*.

Figura 1.2: Flujo de trabajo: web scraping, clasificación de texto, generación de indicadores de innovación, almacenamiento y consulta



Nota. Adaptado de *Web mining for innovation ecosystem mapping: A framework and a large-scale pilot study*, por J. Kinne y A. Axenbeck, 2020, *Scientometrics*, 125(4), 2011–2041.

1.2 Planteamiento del problema

El incremento de los robos en Lima Metropolitana representa una problemática que afecta la seguridad ciudadana y la calidad de vida de la población, y que, a pesar de los esfuerzos institucionales, para identificar de manera oportuna patrones delictivos e implementar estrategias efectivas de prevención continúan siendo un desafío.

En este contexto, el análisis de datos, apoyado en técnicas de *web scraping* y minería de texto, brindan una alternativa innovadora para abordar esta problemática. Sin embargo, aún existe una limitada integración de estas herramientas en el análisis sistemático de la información disponible, lo que dificulta la generación de conocimiento útil para la toma de decisiones.

Por ello, se plantea la necesidad de aprovechar dichas técnicas con el fin de contribuir de manera concreta en la focalización de los robos en Lima Metropolitana. En términos prácticos, este enfoque ayuda en relación al:

1. Desconocimiento de información de noticias de robos en Lima Metropolitana en medios digitales. Actualmente, existe una numerosa cantidad de noticias sobre robos publicadas en medios digitales, portales web y plataformas informativas, las cuales se encuentran dispersas y no estructuradas. Esta división dificulta disponer con una visión sobre el hecho delictivo, obstaculizando la identificación de patrones espaciales, temporales y semánticos asociados a los robos en Lima Metropolitana. La carencia de un sistema de análisis que consolide y resuelva estos textos limita el aprovechamiento de una fuente de información potencialmente valiosa para el entendimiento del contexto urbano de la delincuencia.
2. Valor de la información, es decir con análogos a las fuentes oficiales. Si bien las noticias web constituyen una fuente rica en descripciones y detalles contextuales, su validez frente a los registros oficiales de criminalidad no siempre está claramente establecida. Existen probables diferencias en cuanto a frecuencia, localización geográfica y tipología de los robos registrados, debido a sesgos editoriales, cobertura mediática selectiva o falta de estandarización en la información. Analizar la medida de reciprocidad entre la información extraída de medios digitales y las estadísticas representativas, permitirá evaluar la confiabilidad de estas fuentes alternas y su capacidad de uso complementario en trabajos de seguridad ciudadana.
3. Cómo las noticias web trascienden en la percepción de la población (en contraste a los datos oficiales). Las noticias sobre robos conocidas en medios digitales repercuten directamente en la percepción de inseguridad de la población, muchas veces aumentando la desconfianza del ciudadano más allá de lo manifestado por los datos oficiales. El lenguaje manejado, la reincidencia de ciertos eventos y la focalización en zonas determinadas pueden generar una construcción mediática del robo que no siempre concuerda con la realidad estadística. Concebir esta brecha entre percepción social y registros oficiales resulta primordial para descifrar la percusión de los datos digitales en la opinión pública y en el proceso decisorio tanto individual como institucional.

Antes de empezar con el desarrollo del presente trabajo, se hace presente la siguiente Declaración de uso de IA generativa:

Declaración de uso de IA generativa. En la presente TFM se utilizaron herramientas de IA generativa (*ChatGPT*) como apoyo de redacción, revisión estilística y corrección de textos iniciales. Todo el contenido de este trabajo fue validado, reescrito y comprobado con base en literatura académica y fuentes citadas en el presente trabajo.

No se realizaron tareas como el planteamiento de metodologías, análisis crítico o conclusiones. Se consignan en Anexos en una tabla de trazabilidad de uso de IA.

1.3 Objetivos

1.3.1 General

Identificar patrones espacio temporales en noticias web reportadas en periódicos en Lima Metropolitana - Perú sobre robos durante los años 2020 al 2024.

1.3.2 Específicos

- OE1: Describir comportamientos de los lugares y temporalidades de los robos en Lima.
- OE2: Identificar y agrupar los comportamientos de los robos considerando el espacio y tiempo.
- OE3: Georreferenciar los registros de robos agrupados.

1.4 Justificación

La justificación del presente trabajo es poder contribuir en la problemática social de los robos en Lima, a través de un enfoque de Ciencia de Datos a partir de las siguientes acciones:

1. Detección temprana de zonas y modalidades: El *web scraping* de noticias, redes sociales y foros vecinales concede identificar lugares, horarios y tipos de robo que aparecen con mayor frecuencia, incluso antes de que se manifiesten en robos oficiales.
2. Análisis de patrones y evolución del robo: La minería de texto ayuda a identificar automáticamente por modalidad (arrebato, asalto, moto lineal, transporte público, etc.) y analizar cómo varían en el tiempo, permitiendo priorizar recursos públicos según tendencias reales.
3. Mejor asignación de recursos públicos: Con mapas de calor y análisis espacio-temporal, las autoridades podrían mejorar los patrullajes, uso de cámaras y operativos en lugares críticos, en vez de aplicar tácticas generales pocas prácticas.
4. Reducción de víctimas que no denuncian: Analizar texto en redes sociales y medios digitales como periódicos concediendo capturar experiencias no registradas, disminuyendo el sesgo de las estadísticas fundamentadas solo en denuncias.
5. Diseño de políticas públicas basadas en evidencia: Los productos pueden usarse para campañas de prevención, por ejemplo, horarios y zonas de mayor robo de celulares y para analizar qué medidas realmente funcionan.

En la actualidad, el análisis de datos textuales presenta problemas al momento de realizar estudios, pues existen escasas metodologías para su procesamiento y

tratamiento de forma extendida. Sin embargo, la importancia de los datos textuales en la actualidad reside en su potencial para obtener información relevante a partir del análisis de textos en lenguaje natural, lo que ayuda a concebir patrones de comportamiento, preferencias y opiniones. Estos datos son primordiales en diversos ámbitos, como la investigación académica, el análisis del discurso, la comprobación de información, el proceso decisorio en el ámbito empresarial, etc. El análisis de datos textuales facilita el descubrimiento de vocabulario particular, el estudio de la argumentación, la evaluación institucional, y el entendimiento de las preferencias, patrones de compra de los consumidores, entre otros. Además, en un contexto de sobreabundancia de información, la comprobación se vuelve esencial, y el análisis de datos textuales aporta a contrarrestar información y contribuir mayor parcialidad a una investigación.

Los datos textuales incluyen información que se puede utilizar de variadas formas para una exploración integral, ya sea desde cálculos de palabras hasta la georreferenciación mediante contextos, se refiere al proceso de asociar datos con una ubicación geográfica específica. Es así que, para este presente trabajo, “la georreferenciación es una herramienta beneficiosa que se usará con relación espacial (cartográficamente y geográficamente) por métodos geoestadísticos, los cuales permiten identificar de donde en específico proviene la información” (Giraldo, 2002). En este sentido, los datos textuales para poder ser georreferenciados necesitan ser recolectados mediante un procesamiento, donde se necesita de ciencia de datos que colaboren en la georreferenciación de los datos textuales, siendo este el alcance del presente estudio.

Asimismo, se hace mención que para alcanzar el objetivo de este trabajo se demanda de un proceso que ayude a conseguir los datos (extracción), procesarlos y analizarlos, es decir en síntesis un proceso *Knowledge Discovery in Databases* (KDD), el cual es explicado en el capítulo 2 Estado del arte.

Capítulo 2: Estado del arte

El marco teórico establece el eje conceptual y metodológico que encamina este trabajo, cuyo objetivo es identificar patrones espacio temporales en noticias web reportadas en periódicos en Lima Metropolitana - Perú sobre robos durante los años 2020 al 2024. En este sentido, se enlaza el proceso de Descubrimiento de Conocimiento en Bases de Datos (KDD) como metodología central para extraer, depurar y transformar la información contenida en las noticias digitales en información aprovechable. Este proceso se complementa con herramientas como *web scraping* para la recolección de datos, técnicas de minería de textos, así como con procesos de georreferenciación que posibilitan ubicar territorialmente los hechos identificados.

Primeramente, cabe mencionar la definición de Robo. El delito de robo se encuentra tipificado en el Código Penal peruano. De acuerdo con el Decreto Legislativo N.º 635, se establece que “El que, para procurarse para sí o para otro un provecho ilícito, sustrae un bien mueble, total o parcialmente ajeno, empleando violencia contra la persona o amenaza de un peligro inminente para su vida o integridad física, será reprimido con pena privativa de libertad no menor de tres ni mayor de ocho años” (Perú, 1991, art. 188). Esta definición normativa delimita jurídicamente el fenómeno analizado en el presente estudio, proporcionando el marco legal para la clasificación de los hechos reportados en las noticias digitales.

Asimismo, según la Real Academia Española (s. f.), el término robo se define como la acción y efecto de robar, así como la cosa sustraída. En este sentido, el verbo robar alude a quitar o tomar para sí lo ajeno mediante violencia o fuerza, o incluso a hurtar de cualquier modo. Asimismo, puede referirse al hecho de despojar a una persona de aquello que legal o legítimamente posee, causando un perjuicio con ánimo de lucro. De manera más amplia, el término también puede emplearse para describir la obtención ilegítima de bienes o beneficios, e incluso para aludir metafóricamente a conseguir algo sin merecerlo o sin realizar el esfuerzo correspondiente (Real Academia Española, s. f.).

Por lo tanto, a partir de estas definiciones queda claro que el alcance de robos a ser analizados en este trabajo, son las que no conllevan a un crimen o asesinato de por medio.

A continuación, se presentan algunos conceptos aterrizados al presente trabajo, el cual concluye en la aplicación de la Georreferenciación a los datos textuales usando como herramienta el *web scraping* para la recolección de los mismos.

2.1 Minería de datos

La minería de datos constituye una de las etapas centrales dentro del proceso de Descubrimiento de Conocimiento en Bases de Datos (*Knowledge Discovery in*

Databases o KDD). Fayyad, Piatetsky-Shapiro y Smyth (1996) definen “el KDD como un proceso no trivial orientado a identificar patrones en los datos que sean válidos, novedosos, potencialmente útiles y comprensibles desde una perspectiva humana”. En este sentido, los autores enfatizan que el KDD trasciende la simple aplicación de algoritmos de minería de datos, ya que comprende una secuencia estructurada de etapas que incluyen la selección de datos relevantes, su limpieza y preprocesamiento, la transformación de los mismos, la aplicación de técnicas de minería de datos y, finalmente, la interpretación y evaluación de los resultados obtenidos. De esta manera, el objetivo fundamental del proceso KDD es transformar grandes volúmenes de datos en conocimiento significativo que contribuya a la toma de decisiones y a la comprensión de fenómenos complejos.

Este proceso de KDD aplicado a la presente investigación, se implementó de la siguiente manera:

1. Selección de datos: Esta etapa es la inicial en el proceso KDD, bajo un enfoque de identificación, integración y selección de la información derivada de una o múltiples fuentes, en función del objetivo de análisis, la cual es la etapa que ayuda a definir el nivel de alcance de los datos, reducir la complejidad de la base inicial y determinar el subconjunto o base que será finalmente utilizada dentro del proceso KDD del presente trabajo. En este sentido, haciendo referencia a Fayyad et al. (1996), quienes conceptualizan que “la selección de datos implica decidir qué porción del conjunto total será empleada en el proceso de descubrimiento de conocimiento”, lo cual es pertinente dado que este se enfoca en el análisis de los robos en Lima Metropolitana, mediante la extracción de información en diarios locales publicados en web.

2. Preprocesamiento: La segunda etapa es la de Preprocesamiento, cuyo fin es reducir los errores, inconsistencias y factores aleatorios que afectan los datos. Dicha etapa abarca datos faltantes, eliminación de registros duplicados y la corrección de errores estructurales. En relación a minería de textos, el preprocesamiento implica, además, la eliminación de contenido irrelevante como *spam* y la normalización lingüística. En relación a ello, Han et al. (2012) señalan que “la calidad de los datos constituye un factor crítico en el proceso de minería”, siendo necesario aplicar técnicas de preprocesamiento para eliminar ruido y valores inconsistentes.

3. Transformación de datos: La tercera etapa es la Transformación de datos, la cual se fundamenta en una transformación de la información en un formato apropiado para la aplicación de algoritmos de minería. Esta etapa puede incluir procesos como la normalización, agregación, reducción de dimensionalidad e ingeniería de variables. En el contexto de la minería de textos, la transformación abarca la tokenización, lematización y representación vectorial mediante técnicas como TF-IDF o *embeddings*. En este sentido, Kantardzic (2011) explica que “la transformación de datos tiene como propósito mejorar la eficiencia del proceso analítico y la calidad de los patrones descubiertos”.

4. Minería de datos: La cuarta etapa es propiamente la minería de datos, es decir el centro medular del proceso KDD, debido a que se emplean algoritmos con el objetivo de identificar patrones en los datos. Entre las metodologías más usadas en esta etapa son: el análisis de conglomerados (*clustering*), las reglas de asociación y la detección de anomalías. Asociado a la minería de textos y esta etapa se puede incluir métodos como el modelado de temas, la clasificación automática de documentos y el análisis de sentimiento. En este contexto, Fayyad et al. (1996) explican que “la minería de datos corresponde a la etapa del proceso KDD en la cual se aplican algoritmos para extraer patrones interesantes a partir de los datos”.

5. Evaluación e interpretación: Esta etapa de evaluación e interpretación tiene el objetivo de validar la utilidad y el significado de los patrones hallados en la etapa anterior: la de minería de datos. Esta etapa abarca la validación estadística de los resultados, el análisis de la capacidad de interpretación de los resultados obtenidos y el análisis del significado de los resultados obtenidos. En este contexto, Fayyad et al. (1996) señalan que “no todos los patrones identificados resultan necesariamente útiles, por lo que el proceso de evaluación permite determinar cuáles poseen verdadero interés y valor para la toma de decisiones”.

6. Presentación y uso del conocimiento: La etapa de presentación del conocimiento tiene como fin comunicar los resultados hallados de manera clara y comprensible, con el objetivo de apoyar la toma de decisiones. Para ello, se emplean instrumentos como visualizaciones, reportes analíticos, paneles interactivos (*dashboards*), mapas y otros recursos gráficos que facilitan la lectura de los hallazgos. En este sentido, Han et al. (2012) señalan que “el conocimiento descubierto debe representarse de forma comprensible para el usuario final, asegurando que los patrones identificados puedan ser interpretados y utilizados adecuadamente dentro del contexto del dominio de aplicación”.

Dentro de este marco conceptual, los autores indican que la minería de datos representa la fase central del proceso KDD, ya que es en esta etapa donde se implementan métodos computacionales y estadísticos para extraer regularidades significativas a partir de numerosos volúmenes de información. Mientras que “el KDD comprende el flujo metodológico completo para transformar datos en conocimiento, la minería de datos constituye el núcleo analítico encargado de generar patrones, modelos y estructuras interpretables” (Fayyad et al., 1996).

En cuanto a las tareas primordiales de la minería de datos, Fayyad et al. (1996) indican que “estas pueden asumir una variedad de formas según el objeto de análisis. Una de las primordiales es la clasificación, la cual es construir modelos predictivos capaces de asignar categorías discretas a nuevas observaciones basándose en ejemplos previamente etiquetados”. Este punto de vista resulta especialmente relevante cuando se requiere diferenciar entre tipos de eventos o fenómenos, permitiendo automatizar procesos de identificación y categorización.

Asimismo, los autores definen el *clustering* como una función primordial de la minería de datos. Esta función tiene como propósito determinar estructuras internas en los datos mediante la formación de grupos homogéneos sin necesidad de categorías predestinadas. “El *clustering* resulta especialmente adecuado en estudios exploratorios, donde el fin no es confirmar hipótesis previas, sino revelar patrones emergentes o segmentaciones latentes”, Fayyad et al. (1996).

De igual manera, Fayyad et al. (1996) incluyen “la caracterización como otra función relevante, cuyo fin es generar representaciones compactas y comprensibles de conjuntos de datos complejos”. Esta función puede concretarse a través de descripciones agregadas, substracción de atributos relevantes o técnicas de visualización que faciliten la interpretación humana de los resultados logrados.

En conjunto, estas funciones evidencian que la minería de datos no constituye un procedimiento único, sino un conjunto variado de puntos de vista analíticos orientados a distintos propósitos: predecir, describir, segmentar y sintetizar información. Siendo su aporte fundamental en investigaciones que buscan transformar datos extensos, heterogéneos y complejos en patrones interpretables que respalden la toma de decisiones y la comprensión de fenómenos analizados (Fayyad et al., 1996).

Según Villa Monte (2023), en el material correspondiente al Tema 2: Catálogo de recursos técnicos de la asignatura Minería de Datos de la Universidad Internacional de Valencia, se indican los siguientes conceptos que sirven para especificar las bases para la elaboración del presente trabajo:

- Aprendizaje supervisado establece una correspondencia entre las entradas y las salidas del sistema, donde la base de conocimientos del sistema está formada por ejemplos etiquetados *a priori*.
- Aprendizaje no supervisado el proceso de modelado se lleva a cabo sobre un conjunto de ejemplos formados únicamente por entradas al sistema, sin conocer su clasificación correcta.
- Aprendizaje por refuerzo el algoritmo aprende observando el mundo que le rodea y con un continuo flujo de información en las dos direcciones realizando un proceso de ensayo error, y reforzando aquellas acciones que reciben una respuesta positiva en el mundo.

Por otro lado, la minería de datos y la minería de texto son disciplinas relacionadas que comparten objetivos y técnicas, pero se enfocan en tipos de datos diferentes; en este sentido es necesario primero tener claro las definiciones de ambos.

La minería de datos es definida como la fase del proceso KDD en la cual se aplican algoritmos específicos para extraer patrones a partir de los datos. En este sentido, Fayyad et al. (1996) señalan que “su función principal consiste en descubrir regularidades potencialmente útiles dentro de grandes volúmenes de información”.

Asimismo, los autores destacan que la minería de datos no constituye un proceso completo por sí mismo, sino que representa una etapa esencial dentro del flujo metodológico del descubrimiento de conocimiento, la cual debe complementarse con fases posteriores de interpretación y evaluación para otorgar significado a los patrones identificados.

Diversos autores conceptualizan la minería de textos como el proceso de extracción de conocimiento a partir de datos textuales no estructurados. Hearst (1999) enfatiza que “este proceso implica técnicas específicas de procesamiento del lenguaje natural, diferenciándose de la minería de datos tradicional aplicada a datos estructurados”.

Sobre la base de la definición de minería de datos y minería de texto, y el proceso de KDD, se ha elaborado la siguiente Tabla 2.1 comparativa:

Tabla 2.1: *Comparativo entre Minería de datos y Minería de textos*

Aspecto / Etapa del proceso KDD	Minería de Datos	Minería de Textos	Similitud / Diferencia principal
Tipo de dato principal	Datos estructurados y semiestructurados (tablas, bases de datos y registros numéricos).	Datos no estructurados (documentos, noticias web, textos libres y redes sociales).	Diferencia: el texto necesita estructuración previa mediante NLP.
Selección de datos	Se eligieron variables principales desde bases de datos ordenadas.	Se eligieron documentos textuales relevantes, generalmente de fuentes web o repositorios digitales.	Similitud: ambos necesitan definir fuentes y criterios de inclusión.
Preprocesamiento y limpieza	Limpieza de valores faltantes, duplicados, errores y normalización numérica.	Limpieza lingüística: eliminación de <i>stopwords</i> , corrección, tokenización y lematización.	Diferencia: en textos se requiere procesamiento del lenguaje natural.
Transformación de datos	Conversión a formatos analizables (escalamiento o reducción dimensional).	Conversión del texto en representaciones numéricas: TF-IDF, <i>embeddings</i> y bolsas de palabras.	Similitud: ambos transforman datos a estructuras usables por algoritmos.
Minería de datos (etapa central)	Aplicación de algoritmos para extraer patrones (clasificación,	Aplicación de algoritmos similares, pero sobre variables textuales extraídas o semánticas.	Similitud: comparten tareas analíticas; diferencia: el <i>input</i> textual es más complejo.

	<i>clustering</i> y regresión).		
Interpretación y evaluación	Evaluación estadística de modelos, validación de patrones y métricas numéricas.	Evaluación adicional de coherencia semántica y relevancia contextual del lenguaje.	Diferencia: el significado del texto requiere interpretación lingüística.
Conocimiento útil	Modelos predictivos, reglas de asociación, segmentaciones y patrones cuantitativos.	Descubrimiento de temas, tendencias, relaciones semánticas y eventos descritos en textos.	Similitud: ambos generan conocimiento; diferencia: minería de texto revela contenido temático.
Herramientas comunes	Estadística, machine learning, bases de datos, modelos supervisados, y no supervisados.	NLP, machine learning, análisis semántico y extracción de entidades.	Diferencia: La Minería de textos incorpora herramientas lingüísticas adicionales.
Aplicaciones típicas	Finanzas, industria, fraude, salud, logística y predicción cuantitativa.	Análisis de noticias, opinión pública, redes sociales e inteligencia criminal basada en texto.	Diferencia: Minería de texto se orienta más a fuentes discursivas.
Relación con KDD	Minería de datos es la aplicación de algoritmos para extraer patrones desde datos estructurados.	Minería de texto aplica sobre datos textuales previamente estructurados mediante NLP.	Ambos son parte del proceso KDD, pero con distinta naturaleza de datos.

Nota. *Elaboración propia*

Asimismo, es importante mencionar para este estudio las aplicaciones integradas entre ambas minerías. A menudo, la minería de datos y la minería de texto se combinan para resolver problemas complejos que involucran ambos tipos de datos. Por ejemplo:

- **Análisis de Opiniones en Redes Sociales:** El análisis de opiniones en redes sociales, también llamado análisis de sentimiento, establece un campo de estudio enfocado a la identificación y análisis computacional de opiniones, emociones y actitudes expresadas en texto. En relación a ello, Liu (2012) lo conceptualiza como el estudio computacional de las opiniones y sentimientos presentes en datos textuales, destacando su utilidad para determinar la orientación subjetiva hacia entidades o temas específicos y apoyar procesos de

toma de decisiones basados en grandes volúmenes de información generada por los usuarios.

- **Sistemas de Recomendación:** Los sistemas de recomendación se explican como herramientas y técnicas de *software* planeadas para proporcionar sugerencias personalizadas a los usuarios sobre productos o servicios que podría repercutir de su atracción. En relación a ello, Ricci et al. (2011) explican que estos sistemas funcionan mediante el análisis de preferencias, comportamientos previos e interacciones del usuario, con el propósito de reducir la sobrecarga de información y facilitar la toma de decisiones en entornos digitales caracterizados por una amplia oferta de opciones.

La correlación de la minería de datos y minería de texto es indiscutible en el análisis de Big Data, donde se fusionan datos estructurados y no estructurados para proporcionar una perspectiva más completa y detallada. La minería de datos puede favorecerse de la minería de texto para enriquecer las bases de datos estructuradas con información originada de textos, mejorando así la precisión y la profundidad del análisis. En resumen, aunque la minería de datos y la minería de texto utilizan diferentes tipos de datos y distintas técnicas, ambas están totalmente relacionadas y formando una sinergia para brindar un análisis más completo y detallado.

2.2 Minería de texto

Según lo mencionado en la sección anterior, la Minería de texto busca obtener datos y patrones de una gran cantidad de datos textuales, y para ello se basa en técnicas de la minería de datos, aprendizaje automático, estadística, y Procesamiento de Lenguaje Natural (PLN) para examinar. El propósito principal es convertir el texto en datos estructurados para análisis, descubrimiento de patrones, extracción de entidades, categorización, y otras tareas que permitan la toma de decisiones basada en datos.

La minería de textos nace como una ampliación de la minería de datos encaminada concretamente al análisis de información no estructurada reflejada en lenguaje natural. Hearst (1999) sostiene que, a diferencia de los datos estructurados tradicionales, “los documentos textuales requieren procesos adicionales de representación y técnicas propias del procesamiento del lenguaje natural para posibilitar la extracción de conocimiento”. En este contexto, la autora destaca que la minería de textos abarca funciones asociadas a identificar patrones y estructuras relevantes dentro de enormes colecciones documentales.

Hearst (1999) señala también que esta conjunta varias funciones que vienen del procesamiento del lenguaje natural y la recuperación de información, principalmente se basa en extracción, que posibilita determinar entidades y relaciones dentro de los documentos y convierte el texto no estructurado en visualizaciones analizables y útiles para su interpretación.

Otra función relacionada a la minería de textos es la determinación de temas predominantes en colecciones documentales amplias. Hearst (1999) señala que, por medio de técnicas de agrupamiento y otros métodos, es posible descubrir la estructura temática presente en grandes volúmenes de información. Esta perspectiva ayuda en la determinación de patrones y relaciones de relevancia dentro de medios digitales.

Asimismo, también hace mención que la clasificación de documentos constituye una de las tareas más utilizadas en el ámbito de la minería de textos, dado que esta función implica asignar categorías o etiquetas a los documentos en relación a su contenido, lo que concede organizar y filtrar los datos de forma automatizada. En situaciones similares, resulta especialmente útil para distinguir documentos vinculados a fenómenos particulares, como distintos tipos de robos reportados en noticias digitales.

También menciona que las funciones relacionadas a la minería de textos como la agrupación o *clustering* de documentos, ayuda presentar los textos en grupos homogéneos sin establecer categorías. Esta técnica resulta especialmente útil en análisis exploratorios, ya que facilita la identificación de estructuras latentes dentro del corpus textual y el reconocimiento de subconjuntos temáticos de relevancia.

Por otro lado, la relación entre la minería de textos y la recuperación de información, se considera un complemento de los sistemas tradicionales de búsqueda. En este sentido, la autora (Hearst, 1999) indica que las herramientas de procesamiento del lenguaje natural, ayudan ir más allá de la simple coexistencia de palabras clave, proporcionando una mejor identificación de documentos importantes dentro de numerosas colecciones textuales.

Asimismo, Hearst (1999) hace mención que análisis textual es herramienta que facilita la interpretación humana cuando se trabaja con numerosas colecciones de datos y contribuye a atenuar el exceso informativo en entornos digitales.

Finalmente, las funciones relacionadas a la minería de textos ayudan a convertir documentos en visualizaciones analizables, identificar patrones temáticos, clasificar y agrupar textos, obtener datos relevantes y reproducir estructuras que ayuden su lectura. Es así que, la minería de textos se muestra como una herramienta primordial para el análisis de datos textuales en muchos contextos de aplicación.

2.3 Web scraping

El *web scraping*, también llamada obtención automatizada de datos web, constituye una herramienta empleada para la recolección de información aprovechable del internet, especialmente cuando la información no se muestra en formatos estructurados descargables. Mitchell (2018) explica que este consiste en el uso de programas informáticos que navegan por páginas web y extraen de forma automática información

del contenido, y lo transforma en conjuntos de datos reutilizables para su análisis. Indica también que esta herramienta ayuda a recobrar información de fuentes digitales heterogéneas, como noticias, catálogos o plataformas sociales, ayudando en la reconstrucción de bases de datos a partir de los datos originalmente extraídos.

Cabe mencionar que, el *web scraping* se ha convertido en una herramienta primordial dentro de investigaciones fundadas en variedad de volúmenes de datos, ya que ayuda a acceder a fuentes recientes en tiempo real y obtener información de manera sistemática, y su uso resulta particularmente relevante en contextos donde se requiere analizar dinámicas sociales o fenómenos urbanos reflejados en medios digitales, como ocurre con noticias georreferenciadas o reportes de robos en sitios web.

Clasificación del *web scraping* según el tipo de extracción:

Mitchell (2018) señala que el *web scraping* puede implementarse mediante distintos enfoques técnicos, dependiendo de la estructura del sitio web y del tipo de información que se desea extraer. A partir de estas observaciones, es posible diferenciar varias modalidades operativas según el nivel de complejidad y la interacción requerida con la página.

En primer lugar, se encuentra el *scraping* basado en HTML estático, en el cual el contenido se extrae directamente del código fuente de páginas web tradicionales. Esta clase de *scraping* es común en sitios donde los datos se encuentran accesibles de forma inmediata en el documento HTML y puede ser recuperada mediante selectores o esquemas estructurales.

En segundo lugar, se determina el *scraping* de contenido dinámico, característico de sitios web modernos que cargan información mediante JavaScript. En esas situaciones, es necesario emplear herramientas idóneas de representar la interacción humana o copiar el comportamiento de un navegador, debido a que la información no aparece directamente en el código inicial del sitio web.

Finalmente, Mitchell (2018) describe también a los escenarios del *scraping*, que implican la interacción con estructuras específicas de los sitios web, tales como formularios, motores de búsqueda internos o páginas con múltiples niveles de navegación. En estos casos, el proceso de extracción necesita recorridos automatizados más complejos para acumular información de manera integral.

Esta clasificación ayuda a entender que el *web scraping* no constituye una herramienta única, sino un conjunto de estrategias adaptadas a diferentes arquitecturas web y requerimientos de investigación.

Relación entre *web scraping* y minería de textos:

El *web scraping* conserva una relación estrecha con la minería de textos, especialmente en investigaciones donde la información de interés se presenta en forma narrativa. En

este contexto, el *scraping* describe la fase inicial de obtención de datos textuales desde los sitios web, mientras que la minería de textos implica la fase analítica asociada a la transformación de esos documentos no estructurados en entendimiento beneficioso.

Hearst (1999) indica que la minería de textos se orienta al análisis estructural de grandes colecciones documentales con el fin de identificar patrones, relaciones y estructuras relevantes dentro de información no estructurada. No obstante, para que dicho análisis sea viable en entornos digitales contemporáneos, resulta necesario contar anticipadamente con un corpus textual organizado y sistemáticamente compilado. En este contexto, las técnicas de *web scraping* descritas por Mitchell (2018) permiten automatizar la extracción de contenidos desde páginas web, facilitando la construcción de bases de datos textuales a partir de información originalmente diseñada para el ser humano. De este modo, el *web scraping* se dispone como una fase preliminar necesaria que viabiliza la aplicación posterior de tareas propias de la minería de textos, tales como clasificación de documentos, detección de temas, extracción de entidades o análisis de tendencias.

En investigaciones aplicadas, como el análisis de noticias sobre robos en Lima, el proceso suele estructurarse de manera secuencial: en una primera etapa se recopilan las noticias mediante técnicas de *web scraping* como lo indica Mitchell (2018); posteriormente se realiza el procesamiento del corpus textual, lo que permite aplicar tareas propias de la minería de textos orientadas a la identificación de patrones y relaciones relevantes (Hearst, 1999). Finalmente, los resultados pueden trabajarse juntos con técnicas de georreferenciación para analizar la dimensión espacial del trabajo realizado.

2.4 Georreferenciación

La georreferenciación constituye un concepto primordial dentro de los Sistemas de Información Geográfica (SIG) y el análisis espacial, pues permite relacionar información de variada naturaleza con una ubicación particular en el espacio geográfico. Hill (2006) explica que el proceso implica establecer vínculos entre datos y su localización geográfica, coadyuvando en su organización, visualización y análisis en función del espacio. Esta perspectiva resulta fundamentalmente relevante cuando se trabaja con información originariamente no espacial, como documentos textuales o registros administrativos, que requieren ser asociados a coordenadas o unidades territoriales para su explotación analítica.

Adicionalmente, Hackeloeer et al. (2014) describe que la georreferenciación es un término amplio, que engloba diversos métodos orientados a la identificación de objetos o eventos geográficos. También estos autores (Hackeloeer et al., 2014) señalan que georreferenciar no se restringe a la distribución de coordenadas, sino que complica la aplicación de herramientas que ayudan a localizar entidades de manera indiscutible

dentro de un contexto espacial establecido. Este enfoque amplía la definición hacia una metodología general adaptable tanto a datos estructurados como no estructurados.

Clasificación de la referencia espacial:

Desde un contexto normativo, la Organización Internacional de Normalización (International Organization for Standardization [ISO]) distingue dos enfoques primordiales para la referencia espacial. La norma ISO 19111:2007 (ISO, 2007) indica los principios para la referenciación espacial mediante sistemas de coordenadas; por otro lado, la norma ISO 19112:2003 (ISO, 2003) regula la referenciación por identificadores geográficos, por ejemplo, nombres de lugares o unidades administrativas. Esta diferencia ayuda a entender que la georreferenciación puede realizarse de forma directa, cuando se organiza las coordenadas determinadas, o de forma indirecta, cuando se requiere transformar descriptores espaciales en ubicaciones exactas.

Relación entre georreferenciación y minería de textos:

En investigaciones que utilizan fuentes textuales digitales, como noticias web o redes sociales, la georreferenciación se relaciona con la minería de textos mediante herramientas de reconocimiento de ubicaciones. En este contexto, Leidner (2008) explica el término *geoparsing* que consiste en identificar referencias geográficas en el lenguaje natural, especialmente nombres de lugares o topónimos, y tratarlas como entidades espaciales que deben ser posteriormente localizadas de forma precisa. Este proceso comprende tanto el reconocimiento automático de menciones geográficas como su consecutiva resolución, con el objetivo de determinar una lectura geoespacial apropiada.

En estudios recientes, Tao et al. (2022) señalan que el reconocimiento de entidades geográficas en textos implica identificar expresiones lingüísticas asociadas a ubicaciones y tratarlas como entidades espaciales que puedan ser posteriormente localizadas y analizadas espacialmente. Estos autores subrayan que este proceso, conocido como reconocimiento de entidades geográficas, permite asociar variedad de volúmenes de datos textuales con visualizaciones geoespaciales beneficiosas para su integración en sistemas de información geográfica y herramientas de minería de datos espaciales.

En consecuencia, la relación entre georreferenciación y minería de textos se materializa a través del *geoparsing*, proceso mediante el cual las referencias espaciales vigentes en textos no estructurados son halladas y relacionadas a visualizaciones geográficas formales (Leidner, 2008; Tao et al., 2022). En estudios realizados, como el análisis de noticias georreferenciadas sobre robos, esta integración ayuda convertir distritos, avenidas o zonas urbanas en elementos cartográficos susceptibles de análisis espacial. De esta manera, la minería de textos ayuda con la obtención semántica de ubicaciones, mientras que la georreferenciación facilita su visualización espacial, proporcionando la identificación de patrones territoriales en situaciones urbanas y criminológicas.

2.5 Técnicas aplicadas para datos textuales

Para el análisis de la información textual seleccionada, se aplicaron variedad de técnicas estadísticas que ayudan a convertir datos no estructurados en conocimiento ejecutable. Estas técnicas ayudan a determinar patrones, asociaciones y estructuras subyacentes en el campo de las noticias. Para ello, se emplearon técnicas como la tabla de frecuencias, tabla de contingencias, análisis de correspondencia y análisis de clúster para entender mejor los datos, a continuación, se explica brevemente a que se refiere cada una:

- **Tabla de frecuencias:**

Una tabla de frecuencias constituye una herramienta básica de la estadística descriptiva usada para sistematizar y abreviar datos. Freedman et al. (2007) explican que una tabla de frecuencias es un arreglo sistemático que presenta la distribución de un conjunto de observaciones mediante el conteo del número de veces que cada valor o categoría aparece en los datos. Este tipo de herramienta ayuda a mostrar frecuencias absolutas o relativas, proporcionando la identificación de patrones generales y la representación preliminar del estudio analizado.

- **Tabla de contingencias:**

La tabla de contingencia forma el insumo primordial del análisis de correspondencias. Según Greenacre (2017) es una tabla conformada por frecuencias cruzadas que resumen la distribución conjunta de dos variables categóricas, permitiendo examinar la relación entre sus categorías.

- **Análisis de correspondencia:**

El análisis de correspondencias es una técnica estadística multivariante enfocada en examinar y mostrar gráficamente las asociaciones entre categorías de variables cualitativas a partir de tablas de contingencia. Greenacre (2017) explica que “este método analiza las asociaciones entre filas y columnas mediante la descomposición de la estructura de dependencia, proyectando la información en un espacio geométrico de baja dimensión en el que las distancias entre puntos reflejan la similitud estadística entre categorías”. De este modo, el análisis de correspondencias ayuda en la interpretación de estructuras subyacentes en datos categóricos, brindando visualizaciones gráficas que permiten determinar patrones y asociaciones entre las modalidades estudiadas.

- **Análisis *cluster*:**

El análisis de clúster, también llamado análisis de conglomerados, es una herramienta estadística multivariante cuyo fin es catalogar un conjunto de observaciones en conjuntos homogéneos, de modo que los elementos dentro de cada conjunto presenten mayor semejanza entre sí que respecto a los de otros

conjuntos. Everitt et al. (2011) explican que esta metodología permite identificar estructuras subyacentes en los datos sin recurrir a categorías ya definidas, siendo especialmente útil en estudios exploratorios orientados al descubrimiento de patrones naturales o segmentaciones latentes. En este contexto, el análisis de clúster establece una herramienta de importancia para la disminución de complejidad y la comprensión de relaciones internas en datos multivariantes.

En el presente trabajo se utiliza el dendrograma como herramienta de agrupación jerárquica. El dendrograma es una representación gráfica a manera de árbol empleada en el análisis de clúster jerárquico para ejemplificar el proceso progresivo de agrupamiento de las observaciones. Everitt et al. (2011) señalan que esta representación muestra cómo los elementos individuales se fusionan en conglomerados sucesivos en función de su similitud, permitiendo visualizar la estructura jerárquica de los grupos y seleccionar el nivel de agrupación adecuado mediante el corte del árbol a distintas alturas. De este modo, el dendrograma constituye una herramienta explicativa primordial para entender la formación y relación entre clústeres en un conjunto de datos multivariantes.

2.6 Otras herramientas para analizar datos textuales

Adicionalmente, es relevante señalar la existencia de otras herramientas con finalidades similares o suplementarias, que permiten procesar y analizar los datos textuales:

- **Procesamiento del Lenguaje Natural (NLP):**

El Procesamiento del Lenguaje Natural (NLP) implica una ciencia esencial para el estudio automatizado de textos. Jurafsky y Martin (2026) definen el NLP como un campo interdisciplinario que integra lingüística computacional, inteligencia artificial y aprendizaje automático con el propósito de permitir que las computadoras procesen, interpreten y generen lenguaje humano. En este marco, el NLP suministra las bases técnicas imprescindibles para realizar funciones asociadas a la tokenización, lematización, análisis sintáctico y extracción semántica, fortaleciéndose como un elemento primordial en proyectos de minería de textos implementada.

- **Extracción de Información:**

La extracción de información constituye la técnica primordial para estructurar datos originarios de textos no estructurados. Sarawagi (2008) conceptualiza la extracción de información como “el proceso de identificar automáticamente entidades, relaciones y eventos específicos dentro de documentos textuales, transformando el contenido en datos organizados susceptibles de análisis posterior”. Esta técnica resulta específicamente beneficiosa en el marco de noticias digitales, donde es posible extraer ubicaciones, tipos de robos o actores implicados.

- **Modelado de Temas:**

El modelado de temas implanta una herramienta estadística alineada a reconocer distribuciones temáticas en amplias colecciones de documentos. Blei (2012) expone que “los modelos probabilísticos de temas permiten descubrir automáticamente conjuntos de palabras que tienden a aparecer conjuntamente en los textos, interpretándose como tópicos subyacentes dentro del corpus”. Esta perspectiva ayuda a la investigación exploratoria y la determinación de patrones complejos en documentos extensivos.

- **Representación Vectorial del Texto (TF-IDF y Espacio Vectorial):**

Esta es una herramienta esencial en la minería de textos, ya que es la lectura numérica de documentos a través del modelo de espacio vectorial. Salton y Buckley (1988) indican que este modelo permite representar los textos como vectores de términos ponderados, en los cuales esquemas como TF-IDF asignan mayor peso a aquellas palabras que resultan más discriminantes dentro del corpus. Esta representación posibilita la implementación de algoritmos de clasificación, clustering, entre otras.

- **Reconocimiento de Entidades Nombradas:**

El reconocimiento de entidades nombradas es una herramienta asociada a la determinación y clasificación automática de entidades como personas, lugares u otras categorías dentro de un argumento textual. Nadeau y Sekine (2007) definen que esta herramienta constituye un componente para estructurar información textual, facilitando tareas posteriores como la georreferenciación de noticias o el análisis de actores relevantes en eventos específicos.

- **Análisis de Sentimiento:**

El análisis de sentimiento abarca una técnica considerablemente empleada para analizar percepciones representadas en documentos textuales digitales. Liu (2012) presenta que el análisis de sentimiento es el estudio computacional de opiniones, actitudes y emociones presentes en el lenguaje natural, que se encuentran en contenidos generados por usuarios en plataformas digitales. Esta perspectiva es beneficiosa para examinar la percepción ciudadana sobre acontecimientos como la inseguridad o los robos en ambientes urbanos.

2.7 Marco de referencia

Como antecedente relevante se encuentra la tesis titulada Métricas multivariantes textuales georreferenciadas: Caso aplicado al Estado de Veracruz 2020, elaborada por Hernández Salazar (2020). En dicho estudio se plantea una metodología integral que abarca la obtención de datos, el tratamiento estadístico y la georreferenciación de datos textuales provenientes de sitios web. El estudio demuestra la posibilidad de usar información no estructurada como materia prima analítica, brindando una alternativa

metodológica para investigadores y analistas atraídos en aprovechar fuentes textuales digitales en estudios espaciales.

En el ámbito de los Sistemas de Información Geográfica aplicados a la delincuencia, Espinoza-Ramírez, Nakano, Sánchez-Pérez y Arista-Jalife (2018) realizan un sistema computacional denominado GeoSecurityMX, el cual integra dispositivos móviles y geolocalización para la generación de indicadores delictivos. La metodología propuesta involucra diversas etapas que incluyen: recopilación, procesamiento y visualización cartográfica de información, demostrando el provecho de la georreferenciación para la detección temprana de zonas de riesgo y el apoyo en el proceso decisorio en seguridad pública.

Asimismo, Moreno Jiménez y Grijalva Eternod (2022) proponen un trabajo centrado en los indicadores alternos para la medida de la delincuencia urbana sobre la base de la presencia efectiva de la población, manejando datos georreferenciados de Twitter y del Directorio Estadístico Nacional de Unidades Económicas (DENUE). Los resultados muestran que la incorporación de datos de la actividad urbana permite determinar con mayor exactitud poblaciones en riesgo, destacando el valor del uso de fuentes digitales como proxy de dinámicas sociales.

Desde el enfoque del análisis espacial del robo, Harries (2001) establece las bases conceptuales del *crime mapping*, demostrando cómo la georreferenciación de eventos delictivos ayuda la identificación de patrones espaciales, conglomerados y zonas calientes (*hot spots*). Complementariamente, Chainey, Thompson y Uhlig (2008) analizan si la Estimación de Densidad Kernel (KDE) puede ser una técnica viable para la determinación de concentraciones delictivas, mostrando cómo la conversión de eventos puntuales en superficies continuas mejora el entendimiento espacial del riesgo.

En cuanto a la minería de textos aplicada al crimen, Chen, Chung y Xu (2004) despliegan un marco general para el uso de herramientas de procesamiento del lenguaje natural en el análisis criminal, evidenciando la utilidad de transformar textos no estructurados en variables cuantificables para apoyar la toma de decisiones. De manera complementaria, Wang, Gerber y Brown (2012) señalan que la información de redes sociales georreferenciados puede utilizarse para el pronóstico del crimen urbano, aceptando empíricamente el uso de textos digitales como sensores sociales.

Finalmente, Liu, Andris y Ratti (2011) complementan los datos semánticos con coordenadas geográficas en el análisis urbano, sentando bases metodológicas para la combinación de minería de textos y análisis espacial. Estos antecedentes robustecen la pertinencia de sistematizar extracción textual, análisis estadístico y georreferenciación, como parte del enfoque de la Ciencia de Datos y el Big Data centrados en el estudio de fenómenos delictivos en contextos urbanos como el que se presentan en este trabajo fin de máster.

Capítulo 3: Desarrollo del proyecto

3.1. Metodología

El presente proyecto se enmarca dentro del proceso de KDD, una metodología ampliamente utilizada para transformar grandes volúmenes de datos en información significativa y conocimiento útil. La adopción de esta metodología resulta especialmente pertinente debido a la naturaleza heterogénea y masiva de los datos periodísticos recolectados.

En este contexto, el proceso KDD constituye un marco estructurado para guiar las fases del trabajo, desde la recolección inicial de las noticias hasta la presentación de resultados. Su aplicación no solo permitió organizar el trabajo metodológico, sino también garantizar la trazabilidad de las decisiones técnicas tomadas en cada etapa del desarrollo.

El KDD, en términos generales, se compone de diversas fases encadenadas: selección de datos, preprocesamiento y transformación, minería de datos, evaluación y presentación del conocimiento. Cada una de estas fases aporta valor en el camino hacia la construcción de conocimiento, asegurando que la información sea depurada, normalizada y analizada bajo criterios consistentes.

En el marco del presente proyecto, esta metodología se adaptó para el tratamiento de noticias periodísticas sobre los robos en Lima, con el objetivo identificar patrones mediante un análisis de datos (noticias) entre los años 2020 a 2024. Así, cada fase del KDD fue contextualizada a la naturaleza textual de los datos y al propósito central.

En este contexto, las fases del KDD se materializan a lo largo del desarrollo del trabajo, donde se detallan los procedimientos implementados en cada fase. De este modo, el esquema metodológico actúa como marco de referencia que articula las herramientas técnicas utilizadas, con los objetivos analíticos planteados, garantizando un flujo de procesamiento consistente y orientado al descubrimiento de conocimiento sobre los robos en Lima.

La implementación por cada una de las fases del KDD, aplicada al contexto de este trabajo de investigación, es la siguiente:

1. Selección de datos

La fase de recopilación y almacenamiento de los datos se constituyó como un componente esencial del presente trabajo, al permitir la conformación de una base de noticias periodísticas coherente y estructurada, que funcionó como insumo para la aplicación posterior de las técnicas de preprocesamiento, minería de texto y

georreferenciación. En este contexto, el objetivo no se centró exclusivamente en la obtención de grandes volúmenes de información, sino en garantizar que los datos recolectados fueran pertinentes, trazables y adecuados para los procesos de análisis desarrollados en las etapas posteriores.

Es por tanto el objetivo de esta fase el recopilar las noticias en Lima entre los años 2020 al 2024, en este caso se seleccionó solo para los diarios El Comercio, Gestión, Correo y Ojo. Y para ello, se hizo uso del *web scraping*. Este se realizó mediante la extracción de datos de las noticias de las páginas web de los diarios mencionados, estructurándolos para obtener principalmente el título, el resumen y la fecha, y usando lenguaje de programación R. El código en RStudio del proceso *web scraping* fue almacenado en la plataforma GitHub, ver Anexo I.

Se hace la aclaración que en el código se variaba el `url_noticias` por cada diario y por cada año (todos los días del año), obteniendo así el total de 32411 registros. En algunos años o diarios, debido a restricciones de seguridad no se pudo extraer noticias en dichos diarios o años. El consolidado de todas las noticias considerado en el presente trabajo, fueron almacenados en la plataforma GitHub, ver Anexo I. Se hace la precisión que se hizo un análisis particular para el periodo pandemia (2020 a 2021).

Cabe resaltar, que a consecuencia de la estructura del sitio web y a la necesidad de confirmar progresivamente la calidad de las noticias extraídas, se optó mejor por un proceso controlado por fechas específicas, es decir un proceso semi automatizado. Esto ayudó a comprobar consistencia, prevenir pérdidas de información y garantizar la correcta construcción del conjunto de noticias analizadas.

2. Preprocesamiento y transformación

Este preprocesamiento constituye una fase crítica en el proceso KDD, ya que es el puente entre la recolección bruta de noticias y la posterior minería de texto. Dada la naturaleza heterogénea de las fuentes periodísticas, los datos obtenidos presentaban una serie de retos y la variabilidad en la forma de mencionar ubicaciones o categorías de robos.

Con el preprocesamiento se garantizó que la base de noticias cumpliera con los requisitos mínimos de fiabilidad, completitud y consistencia, asegurando que el análisis posterior estuviera fundamentado en una base de noticias robusta y metodológicamente sólida. Se aplicaron técnicas de limpieza semántica básica, que incluyeron la eliminación de *stopwords* (artículos, preposiciones y conjunciones). Así también, se apoyó en el diccionario de variantes para mapear expresiones como “asalto”, “asaltos” o “asaltante”, todas asociadas a “robo”. Este procedimiento preparó para el conteo sistemático de ocurrencias de palabras y la clasificación posterior por distrito.

En cada registro se distinguió por título, resumen y fecha de la noticia, lo que permitió conservar la estructura para el análisis comparativo entre los distintos niveles. Es por tanto, esta fase el objetivo de una estandarización, normalización y aplicación de georreferenciación; que sirvió de base para la minería de texto. El código en lenguaje de programación R, tanto para todo el periodo (2020 a 2024) como el periodo pandemia (2020 a 2021), asociado al preprocesamiento y transformación fueron almacenados en la plataforma GitHub, ver Anexo I.

3. Minería de Datos / Minería de texto

Esta fase es la de identificación de patrones, para el contexto del presente trabajo, contribuye para la identificación de zonas de mayor incidencia en robos. Para ello, una de las principales herramientas que se usaron fueron el análisis geoespacial, mediante la información de códigos ubigeo de los distritos de Lima; y otras herramientas de apoyo para la evaluación posterior fueron: tabla de frecuencias, matriz de contingencia, dendrogramas y nubes de palabras. El código en lenguaje de programación R para esta fase también fueron almacenados en la plataforma GitHub, ver Anexo I.

El uso de dendrogramas en el presente trabajo se sostiene en la designación del *clustering* jerárquico utilizando la distancia de Gower como medida de similitud para la su construcción. Ello debido a su potencial para analizar matrices con características heterogéneas y estructuras dispersas obtenidas de la minería de textos. Esta distancia es conveniente en contextos donde prevalecen valores nulos y frecuencias variables, pues ayuda a evaluar semejanzas entre distritos considerando la aparición y comportamiento de los términos relacionados a robos, disminuyendo la desviación que podría ocurrir con medidas como la distancia euclidiana. Así también, se usó el método de agrupamiento average linkage, el cual plasma conglomerados a partir de la semejanza promedio entre grupos, permitiendo lograr *clusters* más equilibrados y definidos.

Asimismo, en relación a las nubes de palabras a realizar en el presente estudio, primero en relación a la Nube de palabras del contenido textual, se preestableció un conjunto de términos asociados al término robo, conformado por 44 palabras. Dichos términos no fueron empleados de manera directa para generar la nube de palabras, sino como criterio de filtro semántico para reconocer y elegir aquellas noticias relacionadas con robo. En base a ello, la nube fue generada considerando el contenido textual de los títulos y resúmenes de las noticias filtradas, logrando así representar los términos más frecuentes en noticias asociadas a delitos. Esto permitió reducir ruido temático, mejorar la coherencia del conjunto de noticias analizado y garantizar que la representación visual obtenida refleje el contexto narrativo asociado con los robos reportados en Lima Metropolitana y Callao.

En segundo lugar, con relación a la representación visual de las palabras relacionadas al contexto de robos, la nube fue construida prevaleciendo la visualización completa de todos los términos con frecuencia mayor a cero. Durante las pruebas realizadas, se

observó términos de alta frecuencia y escritura similar, por ejemplo: “Delincuente” y “Delincuentes” tendían a superponerse o omitirse debido a restricciones espaciales propias de los algoritmos de distribución gráfica. Por esta razón, se eligió por una distribución visual menos compacta, ayudando así a disminuir superposiciones y garantizar la representación de todos los términos con frecuencia mayor a cero. Por tanto, aunque la nube de palabras muestra mayores espacios entre palabras en relación a nubes puramente estéticas, esta decisión metodológica beneficia la integridad y legibilidad del análisis textual del estudio.

En tercer lugar, en relación a la nube de palabras asociada a los distritos, de igual modo su representación fue establecida prevaleciendo la integridad y legibilidad de la información antes que una distribución visual rigurosamente estética. En este caso, se halló que algunos distritos con frecuencias mayor a cero, principalmente aquellos con nombres largos como San Juan de Lurigancho o San Martín de Porres o entre otras, eran obviados por limitaciones de espacio del algoritmo. Por este motivo, se eligió por una distribución controlada de las etiquetas (se usó abreviaturas), permitiendo visualizar la totalidad de los distritos del estudio sin perder proporcionalidad en función de sus frecuencias. En consecuencia, aunque la disposición final no muestra la forma clásica compacta de una nube, esta decisión metodológica permite una representación más completa, e interpretable de los resultados, lo cual resulta más adecuado para fines analíticos dentro del tenor del presente estudio.

4. Evaluación

La fase de Evaluación actúa como un puente entre el análisis técnico y la toma de decisiones, garantizando que los patrones identificados sobre robos en Lima no solo sean estadísticamente correctos, sino también socialmente relevantes y útiles. Es así que, el objetivo de esta evaluación es ver la validez, coherencia, interoperabilidad y utilidad práctica de los patrones identificados mediante técnicas de minería de datos y análisis geoespacial, con el fin de asegurar que el conocimiento obtenido represente adecuadamente la dinámica de los robos en Lima y sea relevante para la toma de decisiones en seguridad ciudadana. Para ello, será parte de la evaluación responder las siguientes preguntas:

- ¿Los patrones de robos identificados son consistentes a lo largo del período analizado y no responden a eventos aislados o aleatorios?
- ¿Existe coherencia entre los resultados obtenidos mediante tablas de frecuencia, matrices de contingencia y análisis geoespacial?
- ¿Los distritos identificados como críticos presentan una lógica espacial coherente con la estructura urbana y socioeconómica de Lima?
- ¿Los agrupamientos de distritos obtenidos mediante dendrogramas son interpretables y socialmente coherentes?
- ¿Los resultados pueden ser comprendidos y utilizados por autoridades locales y actores no especializados en análisis de datos?

5. Presentación del conocimiento

El objetivo de esta fase es presentar de forma clara, comprensible y orientada a la toma de decisiones el conocimiento validado sobre los patrones de robos en Lima, mediante visualizaciones y resúmenes interpretativos que permitan su aplicación práctica en la gestión de la seguridad ciudadana. Los resultados se presentan utilizando mapas temáticos, gráficos estadísticos y resúmenes interpretativos, permitiendo identificar distritos críticos, modalidades de robo predominantes y patrones territoriales de manera intuitiva.

Esta etapa se subdivide a su vez en las siguientes etapas listadas a continuación:

1. Interpretación de patrones: Consiste en analizar el significado de los resultados obtenidos mediante minería de datos y determinar su relevancia en el contexto del problema. Aquí se traduce el hallazgo técnico en una explicación comprensible.
2. Evaluación del conocimiento descubierto: Implica validar que los patrones encontrados sean: correctos (válidos), novedosos, útiles, y no producto del azar. Esta evaluación puede incluir métricas estadísticas.
3. Visualización del conocimiento: Es una etapa esencial en la cual los patrones se presentan mediante: gráficos, mapas, dendrogramas, representaciones geoespaciales. Han et al. (2012) destacan que la visualización facilita la comprensión humana del conocimiento extraído.
4. Presentación y comunicación al usuario final: El conocimiento debe organizarse en reportes o productos interpretables para apoyar la toma de decisiones. Esto puede incluir: informes analíticos, mapas de riesgo y modelos predictivos explicados.
5. Integración del conocimiento en procesos de decisión: Finalmente, el conocimiento descubierto puede ser incorporado en sistemas reales, políticas públicas o modelos de monitoreo. En criminología urbana, esto puede traducirse en alertas, focalización territorial o estrategias de prevención.

Figura 3.1: *Etapas de la presentación del conocimiento*



Nota. *Elaboración propia.*

3.2 Descripción de los datos

Los datos analizados provienen de cuatro diarios de relevancia nacional, y de cinco años del 2020 al 2024, con el objetivo de obtener una mayor trazabilidad. Todos los datos fueron extraídos de la página web de cada diario usando códigos de programación en R, y delimitando la extracción principalmente en los atributos de la noticia: Título, Resumen, Fecha y Hora.

Tabla 3.1: *Resumen final: Cantidad de noticias por año y por diario (2020–2024)*

Año	Diario	Cantidad de noticias analizadas
2020	Correo	1040
2020	El Comercio	5999
2020	Gestión	0
2020	Ojo	19
2021	Correo	2320
2021	El Comercio	583
2021	Gestión	50
2021	Ojo	2
2022	Correo	2762
2022	El Comercio	73
2022	Gestión	677
2022	Ojo	11
2023	Correo	249
2023	El Comercio	2860

2023	Gestión	880
2023	Ojo	977
2024	Correo	5804
2024	El Comercio	5600
2024	Gestión	1500
2024	Ojo	1005
		32411

Nota. *Elaboración propia.*

Asimismo, cabe mencionar si bien el estudio tiene en el objetivo como alcance Lima Metropolitana, los análisis textuales y multivariantes incluyeron adicionalmente registros de la Provincia Constitucional del Callao (sus 7 distritos) debido a su estrecha articulación territorial y urbana con Lima Metropolitana. Esta integración se aprecia en la continuidad geográfica, los flujos de movilidad, la interacción económica y la cobertura conjunta por los medios de comunicación, los cuales frecuentemente reportan hechos de robo de Lima y Callao como parte de un mismo entorno. En consecuencia, la inclusión del Callao permitió obtener unos resultados más integrales de los patrones asociados a robos dentro del contexto urbano en estudio.

Capítulo 4: Hallazgos encontrados

4.1. Extracción de datos

Los datos extraídos corresponden a diarios web nacionales de relevancia en el Perú, los cuales son: El Comercio, Gestión, Correo y Ojo. Estos datos pertenecen a registros entre los años 2020 al 2024, que fueron recolectados a partir de una extracción de los datos de la página web de cada diario usando códigos en lenguaje de programación R (proceso *web scraping*); se anexa al presente trabajo los datos extraídos. Como se indicó anteriormente, el consolidado de noticias extraídas y el código *web scraping* para obtener dicho consolidado fueron almacenados en la plataforma GitHub, ver Anexo I.

4.2. Análisis de los datos

4.2.1 Descripción

El global de los datos analizados fue de 5 años, entre los años 2020 al 2024. La distribución de estos se muestra a continuación (obtenido del código de programación establecido), en relación a las palabras relacionadas a robo, así como la distribución en relación a los distritos de Lima Metropolitana (primeros 43 distritos) y el Callao (últimos 7 distritos).

Tabla 4.1: *Frecuencia de palabras asociadas a Robo - Período 2020 a 2024*

N.º	Palabra	Frecuencia
1	Asalto	69
2	Asaltos	15
3	Asaltante	3
4	Asaltantes	11
5	Asaltar	22
6	Asaltaron	12
7	Asalta	0
8	Delincuencia	51
9	Delincuente	59
10	Delincuentes	201
11	Delinquir	3
12	Robos	45
13	Robo	129
14	Robaba	6
15	Robaban	7
16	Robaron	23
17	Rateros	1

18	Ratero	0
19	Roba	24
20	Robar	71
21	Ladrones	44
22	Ladrón	23
23	Raquetero	0
24	Raqueteros	0
25	Latrocinio	0
26	Despojo	0
27	Rapiña	0
28	Saqueo	3
29	Atracos	4
30	Atraco	11
31	Expropiación	3
32	Extorsión	44
33	Hurto	17
34	Sustracción	3
35	Estafas	12
36	Estafadores	5
37	Estafa	27
38	Estafan	3
39	Hampones	42
40	Hampón	8
41	Sustrae	0
42	Sustraer	9
43	Maleante	0
44	Maleantes	15

Nota. *Elaboración propia*

Tabla 4.2: *Frecuencia de robos reportados por Distritos - Período 2020 a 2024*

Nº	Distrito	Frecuencia
1	Ancón	1
2	Ate	4
3	Barranco	1
4	Breña	0
5	Carabayllo	3
6	Chaclacayo	0
7	Chorrillos	6
8	Cieneguilla	0
9	Comas	12

10	El Agustino	6
11	Independencia	2
12	Jesús María	2
13	La Molina	4
14	La Victoria	5
15	Cercado de Lima	3
16	Lince	0
17	Los Olivos	10
18	Chosica	0
19	Lurín	2
20	Magdalena del Mar	2
21	Miraflores	13
22	Pachacámac	0
23	Pucusana	0
24	Pueblo Libre	1
25	Puente Piedra	8
26	Punta Hermosa	1
27	Punta Negra	0
28	Rímac	1
29	San Bartolo	0
30	San Borja	4
31	San Isidro	3
32	San Juan de Lurigancho (SJL)	14
33	San Juan de Miraflores (SJM)	4
34	San Luis	3
35	San Martín de Porres (SMP)	13
36	San Miguel	4
37	Santa Anita	1
38	Santa María del Mar	0
39	Santa Rosa	1
40	Santiago de Surco	0
41	Surquillo	1
42	Villa el Salvador (VES)	4
43	Villa María del Triunfo	0
44	Callao	13
45	Ventanilla	3
46	Carmen de la Legua Reynoso	0
47	Bellavista	1
48	La Perla	0
49	Mi Perú	0
50	La Punta	0

Nota. Elaboración propia

Por otro lado, para el caso del periodo 2020 a 2021, años en que ocurrió la pandemia del Coronavirus o COVID-19 en el Perú, la distribución de los datos en específico es como es muestra a continuación:

Tabla 4.3: *Frecuencia de palabras asociadas a Robo - Período 2020 a 2021*

N.º	Palabra	Frecuencia
1	Asalto	26
2	Asaltos	5
3	Asaltante	0
4	Asaltantes	2
5	Asaltar	10
6	Asaltaron	1
7	Asalta	0
8	Delincuencia	9
9	Delincuente	18
10	Delincuentes	34
11	Delinquir	0
12	Robos	9
13	Robo	30
14	Robaba	2
15	Robaban	4
16	Robaron	8
17	Rateros	0
18	Ratero	0
19	Roba	6
20	Robar	20
21	Ladrones	8
22	Ladrón	10
23	Raquetero	0
24	Raqueteros	0
25	Latrocinio	0
26	Despojo	0
27	Rapiña	0
28	Saqueo	0
29	Atracos	1
30	Atraco	3
31	Expropiación	2
32	Extorsión	4
33	Hurto	0
34	Sustracción	0
35	Estafas	1

36	Estafadores	1
37	Estafa	6
38	Estafan	1
39	Hampones	14
40	Hampón	1
41	Sustraer	0
42	Sustraer	2
43	Maleante	0
44	Maleantes	3

Nota. *Elaboración propia*

Tabla 4.4: *Frecuencia de robos reportados por Distritos - Período 2020 a 2021*


Nº	Distrito	Frecuencia
1	Ancón	0
2	Ate	0
3	Barranco	1
4	Breña	0
5	Carabaylo	1
6	Chaclacayo	0
7	Chorrillos	2
8	Cieneguilla	0
9	Comas	4
10	El Agustino	2
11	Independencia	1
12	Jesús María	0
13	La Molina	0
14	La Victoria	2
15	Cercado de Lima	2
16	Lince	0
17	Los Olivos	3
18	Chosica	0
19	Lurín	0
20	Magdalena del Mar	0
21	Miraflores	2
22	Pachacámac	0
23	Pucusana	0
24	Pueblo Libre	0
25	Puente Piedra	2
26	Punta Hermosa	1
27	Punta Negra	0
28	Rímac	0

29	San Bartolo	0
30	San Borja	0
31	San Isidro	1
32	San Juan de Lurigancho	1
33	San Juan de Miraflores	0
34	San Luis	2
35	San Martín de Porres	3
36	San Miguel	0
37	Santa Anita	0
38	Santa María del Mar	0
39	Santa Rosa	0
40	Santiago de Surco	0
41	Surquillo	0
42	Villa el Salvador	2
43	Villa María del Triunfo	0
44	Callao	4
45	Ventanilla	1
46	Carmen de la Legua Reynoso	0
47	Bellavista	0
48	La Perla	0
49	Mi Perú	0
50	La Punta	0

Nota. *Elaboración propia*

Como se puede apreciar de las tablas de frecuencias de robos reportados por distrito durante el periodo 2020–2024 en Lima Metropolitana fueron los de mayor incidencia: San Juan de Lurigancho, Miraflores, San Martín de Porres y Comas. Sin embargo, durante el periodo de pandemia, como se aprecia en la tabla de frecuencia, fueron los distritos de mayor incidencia en Lima Metropolitana: Comas, San Martín de Porres y Los Olivos.

Figura 4.1: *Gráfico de líneas de la distribución de noticias (2020 al 2024)*



Nota. *Elaboración propia*

El gráfico de líneas demuestra una caída en la frecuencia de noticias asociadas a robo en los años 2021 y 2022, debido a que aún la población limeña estaba saliendo de confinamiento, es por ello desde el 2023 vuelve a aumentar dicha frecuencia.

Así también, como parte del análisis, para una mejor visualización de la distribución de las palabras asociadas a robo, tanto en el periodo 2020 a 2024 como para el periodo de pandemia (2020 a 2021), se empleó la herramienta Nube de palabras, tanto del contenido textual (título y resumen de la noticia), palabras asociadas a robo, y en relación a los robos por distrito. A continuación, se muestra los resultados respectivos:

Figura 4.2: *Nube de palabras del contenido textual – periodo 2020 al 2024*






Figura 4.3: *Nube de palabras del contenido textual – periodo 2020 al 2021*



Como se puede apreciar comparando las nubes de palabras del contenido textual del periodo 2020-2024 con el del periodo pandemia, coincide en que las palabras “delincuentes”, “policía” y “robo” son términos de alta frecuencia. Sin embargo, se puede apreciar en la nube del periodo 2020-2024 más palabras asociadas a “robo”, y ello coincide más con los análisis previos, debido a que durante el periodo de pandemia la frecuencia de robos disminuyó.

Figura 4.4: Nube de palabras asociadas a Robo – periodo 2020 al 2024



Nota. Elaboración propia

Figura 4.5: Nube de palabras asociadas a Robo – periodo 2020 al 2021



Nota. Elaboración propia

Como se aprecia al comparar ambas nubes de palabras asociadas a robo, los resultados en ambos periodos son semejantes manteniéndose palabras con alta frecuencia como “Robo”, “Robar”, “Delincuentes” en ambos periodos, ello sugiere a concluir principalmente que existe un relativo equilibrio en el vocabulario manejado por los diarios digitales para comunicar noticias asociadas a robos.

Asimismo, también se realizó una Nube de palabras tanto para el periodo 2020 a 2024 como para el periodo de pandemia (2020 a 2021), considerando los distritos de Lima Metropolitana y del Callao, es decir los 50 distritos. Los resultados se muestran a continuación:

Figura 4.6: *Nube de palabras asociadas a Distritos – periodo 2020 al 2024*



Nota. *Elaboración propia*

Figura 4.7: *Nube de palabras asociadas a Distritos – periodo 2020 al 2021*



Nota. *Elaboración propia*

De igual modo, como en la comparación anterior, estas nubes demuestran que durante el periodo 2020–2024 en Lima Metropolitana fueron los de mayor incidencia: San Juan de Lurigancho (SJL), Miraflores, San Martín de Porres (SMP) y Comas. Mientras que durante el periodo de pandemia (2020-2021), fueron los distritos de mayor incidencia en Lima Metropolitana: Comas, San Martín de Porres y Los Olivos.

Así también, se hace mención como parte del análisis que se realizó una matriz de contingencia para ambos periodos (2020 a 2024) y (2020 a 2021). Ambas matrices fueron almacenadas en la plataforma GitHub, ver Anexo I. Ello con la finalidad de organizar la distribución conjunta entre modalidades léxicas asociadas al robo y distritos de Lima, permitiendo cuantificar la frecuencia de co-ocurrencia entre ambas variables categóricas. Esta estructura constituye el insumo fundamental para el análisis de correspondencias, ya que posibilita explorar asociaciones territoriales y patrones espaciales a partir de datos textuales previamente georreferenciados.


La matriz de contingencia permitió analizar la relación entre palabras asociadas a robo y distritos. En contraste a la nube de palabras, que se diseña a nivel univariada, la matriz de contingencia inserta una perspectiva bivariado que facilita determinar patrones de co-ocurrencia entre categorías.

La matriz de contingencia muestra que entre las palabras con mayor frecuencia destacan: “Delincuentes”, “Robo”, “Delincuente” y “Asalto”, demostrando los análisis previos. Asimismo, los distritos con mayores asociaciones corresponden mayormente a Miraflores, San Martín de Porres, Callao, San Juan de Lurigancho, Comas, Puente Piedra y Los Olivos, demostrando así una mayor presencia de noticias relacionadas con robos en dichos distritos. En conjunto, la matriz permite determinar patrones de coocurrencia entre términos de delincuencia y espacios geográficos específicos, estableciendo una base importante para los posteriores análisis multivariantes y espaciales del presente estudio.

Por otro lado, la matriz de contingencia del periodo pandemia (2020–2021) muestra que, pese a las restricciones de movilidad y medidas sanitarias implementadas, las noticias asociadas a robos siguieron presentando una fuerte asociación entre términos relacionados a robo y varios distritos de Lima Metropolitana y Callao. Se subraya nuevamente palabras como “Delincuentes”, “Delincuente”, “Robo” y “Asalto”, lo que evidencia la subsistencia de un discurso periodístico centralizado en actos delictivos urbanos inclusive en un contexto de pandemia. Así también, algunos distritos tienen una alta frecuencia de relación con dichas palabras, apuntando consecuencia espacial durante la pandemia. Por tanto, la matriz demuestra que el fenómeno de robos comunicado digitalmente conservó patrones textuales y territoriales relativamente estables incluso en un contexto de emergencia sanitaria.


A continuación, como consecuencia de las matrices de contingencia se muestra los Análisis de correspondencia en ambos periodos.

Figura 4.8: *Análisis de correspondencia – periodo 2020 al 2024*



Nota. *Elaboración propia*

Figura 4.9: *Análisis de correspondencia – periodo 2020 al 2021*



Nota. *Elaboración propia*

El análisis de correspondencias del periodo 2020–2024 muestra asociaciones particulares entre algunos términos relacionados al contexto delincucional y ciertos distritos de Lima Metropolitana y Callao. La concentración de la mayoría de los términos y distritos en torno al origen insinúa la presencia de patrones parcialmente compartidos en la cobertura periodística de robos; no obstante, algunos términos presentan relaciones más concretas y específicas. Por ejemplo, las asociaciones entre “Sustraer” y “Robaban” con Punta Hermosa, así como la cercanía entre “Saqueo” y Magdalena del Mar, lo cual revelaría comportamientos específicos dentro de dichos distritos. Así también, palabras como “Asaltante”, “Ladrones” y “Robaron” muestran lugares más alejadas del centro, mostrando relaciones menos frecuentes, pero más particulares respecto a algunos distritos. En resumen, el análisis de correspondencia ayuda a


determinar patrones semánticos y territoriales específicos dentro del contexto de robos comunicado digitalmente.

Por otro lado, el análisis de correspondencias del periodo de pandemia (2020–2021) demuestra que la gran cantidad de términos relacionados a robos y distritos se agrupan entorno al origen también, lo que insinúa patrones relativamente homogéneos en la cobertura periodística de actos delincuenciales durante este periodo. Sin embargo, algunos términos presentan relaciones más específicas, como la cercanía entre “Robaban” y determinados distritos como San Isidro y Punta Hermosa, así como la relación entre “Asaltaron” y Barranco. Así también, palabra como “Hampones” muestra un comportamiento más específico en contraste al resto de palabras examinadas. En resumen, el análisis muestra que, incluso durante la pandemia, subsistieron relaciones territoriales y semánticas particulares dentro de las noticias digitales asociadas a robos.

4.2.2 Agrupación de información


Para la agrupación, se realizaron *clustering* representado en dendrogramas, los cuales muestran la cantidad de *clusters* tanto para el periodo de los años 2020 a 2024, y para el periodo de pandemia 2020 a 2021, asociado a los distritos. Los dendrogramas respectivos se pueden ver en las siguientes figuras:

Figura 4.10: *Dendrograma de palabras asociadas a los Distritos – periodo 2020 a 2024*



Nota. *Elaboración propia*

Figura 4.11: *Dendrograma de palabras asociadas a los Distritos – periodo 2020 a 2021*




Nota. *Elaboración propia*

Como parte de la agrupación, la aplicación de dendrogramas a las palabras asociadas a los distritos facilitó la determinación de estructuras jerárquicas dentro del conjunto de noticias, demostrando relaciones de similitud entre las zonas territoriales en estudio. El dendrograma basado en el estudio de clúster jerárquico, ayuda a relacionar distritos debido a la similitud de los términos con los que son denominados en las noticias, lo cual representa una cercanía indirecta a la caracterización del hecho delictual en cada distrito.

Otro aspecto importante es que el dendrograma ayuda a determinar distritos atípicos, es decir, que no se congregan sin dificultad con otros. Estas situaciones podrían entenderse como zonas con atributos específicos en cuanto a la frecuencia de algunos tipos de delitos, esto representa un insumo esencial para un estudio más focalizado.


De los dendrogramas obtenidos se seleccionó un $K = 6$ (número de *clusters*), se realizó mediante inspección visual obtenido mediante agrupamiento jerárquico empleando distancia de Gower, determinándose seis conglomerados particulares. Esta cantidad permitió mantener un equilibrio entre diferenciación y afinidad interna de los grupos, evitando así una segmentación excesiva como una agrupación muy general de los distritos. Así también, la elección de seis *clusters* ayudó en la interpretación más clara de los patrones territoriales relacionados a los términos vinculados a robos dentro del contexto estudiado. Asimismo, esta división de *clusters* permite la posibilidad de establecer políticas antirrobo por cada grupo de distrito (*cluster*) establecido, logrando así una mejor eficiencia de la gestión estatal. A continuación, se muestran los *clusters* determinados para cada periodo (que distritos estarían en cada *cluster*):

Figura 4.12: *Clusters identificados en dendrograma – periodo 2020 a 2024*



Nota. *Elaboración propia*

Figura 4.13: *Clusters identificados en dendrograma – periodo 2020 a 2021*




Nota. *Elaboración propia*

4.2.3 Análisis Espacial


El análisis por georreferenciación se realizó mediante la obtención de un mapa nacional de Lima (Lima Metropolitana y Callao), y ver cómo se distribuyen la frecuencia de las noticias en los distritos. Para ello, también se usó códigos en lenguaje de programación R, solo considerando los 43 distritos de Lima Metropolitana (ver código en Anexo I).

Figura 4.14: *Mapa de robos reportados en noticias web – periodo 2020 a 2024*



Nota. *Elaboración propia*

Figura 4.15: *Mapa de robos reportados en noticias web – periodo 2020 a 2021*



Nota. *Elaboración propia*

Estos mapas presentados demuestran visualmente y geo referencialmente, todo el análisis previo mostrando aquellos distritos con mayor incidencia de robo (zonas sombreada de amarillo) y de color anaranjado las de un poco menor incidencia, y las sin incidencia (según data analizada): de color azul. Su aplicación sería de mucha utilidad dentro de una gestión pública municipal o regional. Se reitera la aclaración que, para el presente estudio y objetivo, para la georreferenciación, solo se construyó el mapa considerando la frecuencia de los 43 distritos de Lima Metropolitana.

El análisis espacial implementado en el presente trabajo facilitó integrar la dimensión geográfica con los datos textuales, estableciendo una de las primordiales aportaciones metodológicas del trabajo. Mediante el proceso de georreferenciación, las noticias

fueron relacionadas a distritos particulares, convirtiendo datos no estructurados en datos espacialmente comprensibles.

Cabe mencionar, que el análisis espacial debe analizarse teniendo en cuenta la fuente de datos. En virtud que se trata de noticias de diarios locales, los resultados muestran no solo la incidencia del robo, sino además su claridad mediática. Por tanto, distritos con mayor movimiento económico, flujo poblacional o cobertura informativa pueden mostrar una representación desproporcionada en la información, lo cual introduce un ingrediente de sesgo que debe ser apreciado en el análisis.

4.2.4. Resultados de la Evaluación

Corresponde ahora responder las preguntas planteadas en la fase de Evaluación (sección anterior) las cuales son:

¿Los patrones de robos identificados son consistentes a lo largo del período analizado y no responden a eventos aislados o aleatorios?

Como se demostró en las nubes de palabras y dendrogramas, los resultados fueron similares, independientemente del periodo que vengan, es decir sea del 2020 a 2024 o del periodo pandemia (2020 a 2021). Por tanto, no existen eventos aislados durante el análisis.

¿Existe coherencia entre los resultados obtenidos mediante tablas de frecuencia, matrices de contingencia y análisis geoespacial?

Sí, por ejemplo, los resultados de la tabla de frecuencias, nubes de palabras y mapas muestran que los distritos con mayor incidencia en robos son: “Independencia”, “La Victoria”, “Miraflores”.

¿Los distritos identificados como críticos presentan una lógica espacial coherente con la estructura urbana y socioeconómica de Lima?

No necesariamente, por ejemplo, en el caso del distrito de Miraflores, es un distrito con alta percepción de seguridad en la ciudadanía debido a que predominan los niveles socioeconómicos A y B (población de alto nivel social económico); sin embargo, los resultados de la frecuencia de robos muestran es mayor que incluso distritos de los que en Lima se les dice como “distritos conos”, como San Martín de Porres y Los Olivos.

¿Los agrupamientos de distritos obtenidos mediante dendrogramas son interpretables y socialmente coherentes?

Sí, pues se aprecia como los dendrogramas por distritos se han agrupado sobre la base de la frecuencia de robos reportados en noticias web, lo que genera una clasificación coherente. Se demuestra con la agrupación de *clusters* realizada para los 6 grupos en cada periodo.

¿Los resultados pueden ser comprendidos y utilizados por autoridades locales y actores no especializados en análisis de datos?

Sí, los resultados podrían ser usados para asignación de recursos públicos y diseño de políticas públicas basadas en evidencia y considerando la agrupación sugerida en los dendrogramas.

Capítulo 5: Conclusiones

5.1. Conclusiones del trabajo

Respecto a los objetivos específicos, el primero se cumplió a través del análisis de frecuencias anuales, palabras asociados a robos y distribución de noticias por distritos, ayudando a describir conductas espaciales y temporales del fenómeno. El segundo objetivo se plasmó a través de la matriz de contingencia, el análisis de correspondencias y el dendrograma, determinando relaciones y agrupamientos entre palabras relacionadas a robo y distritos. Finalmente, el tercer objetivo se logró a través de la georreferenciación de los registros relacionados a robos empleando información distrital y límites espaciales de Lima Metropolitana, ayudando a visualizar territorialmente la distribución de noticias vinculadas al estudio.

En relación con el primer objetivo específico, la evaluación mediante análisis de frecuencias y nube de palabras, permitiendo describir comportamientos particulares de lugares y temporalidades de robos en Lima Metropolitana.

Respecto al segundo objetivo específico, la aplicación de la herramienta dendrograma a nivel de distrito, permitió agrupar los comportamientos de los robos considerando el espacio y tiempo. Obteniéndose un nivel de *cluster* de 6 como se demostró en el análisis realizado, ello porque determinar un nivel óptimo de disimilitud es donde se maximizan las diferencias entre *clusters* y se conserva la homogeneidad interna.

En términos generales, este trabajo evidencia como el *web scraping*, la minería de texto y la georreferenciación, aunque son disciplinas distintas dentro de la ciencia de datos, se complementan y se potencian mutuamente cuando se combinan. Asimismo, los resultados obtenidos aportan una visión integral sobre la representación de los robos en los distritos de Lima Metropolitana durante los años 2020 al 2024, con fines de contribuir en soluciones ante la problemática social.

El objetivo general de la investigación se cumplió a través del uso de herramientas de minería de texto, análisis multivariante y georreferenciación de las noticias web asociadas con robos entre los años 2020 y 2024 en Lima Metropolitana y Callao. Con el procesamiento de resúmenes, títulos y términos relacionados a robo y referencias distritales, fue posible determinar patrones espaciales y temporales asociados a la ocurrencia y cobertura de noticias de robos, soportándose en tabla de frecuencias, matrices de contingencia, análisis de correspondencias, dendrogramas y representación cartográfica distrital.

La caracterización cartográfica de los resultados facilita una visualización entendible e instintiva de los patrones hallados, ayudando su entendimiento y comunicación. En relación al proceso KDD, el análisis espacial corresponde a la fase de presentación del

conocimiento, donde los resultados son convertidos en modelos entendibles para la toma de decisiones.

Adicionalmente, a los objetivos planteados, es preciso relacionar el presente trabajo con los Objetivos de Desarrollo Sostenible (ODS) establecidos por la Agenda 2030 de las Naciones Unidas. Y en relación a ello, se hace referencia al ODS 16: Paz, justicia e instituciones sólidas, por ser el ODS con más afinidad, cuyas metas relacionadas son:

16.1 Reducir significativamente todas las formas de violencia y las tasas de mortalidad relacionadas en todo el mundo.

16.6 Crear instituciones eficaces, responsables y transparentes en todos los niveles.

16.a Fortalecer las instituciones nacionales pertinentes para prevenir la violencia y combatir el terrorismo y la delincuencia.

En consecuencia, el presente trabajo aportaría al cumplimiento del ODS 16 de la Agenda 2030, al generar evidencia sobre la delincuencia urbana en Lima Metropolitana, a partir del análisis de noticias periodísticas, favoreciendo la mejor implementación de políticas públicas y el rol de los medios de comunicación en la construcción social del robo.

5.2. Limitaciones técnicas y oportunidades de mejora

Si bien el proceso logró consolidar una base de datos robusta y útil para los objetivos planteados, también se identificaron limitaciones técnicas que es necesario reconocer. Entre ellas se hace mención que:

- La dependencia del histórico de noticias, lo que en algunos casos supuso obtener de manera parcial el contenido en algunos diarios y años, ello debido a controles internos de seguridad propios del sitio web.
- La falta de heterogeneidad de las estructuras de los códigos de base de datos del histórico de noticias, limitando que el código *web scraping* que se proponga se limite a solo ciertos campos relevantes.

A pesar de estas limitaciones, el sistema *web scraping* desarrollado presenta varias oportunidades de mejora y ampliación. Entre las oportunidades identificadas, se tiene la posibilidad de integración con otras bases de diarios o de instituciones públicas que amplíen la cobertura temporal, y el desarrollo de dashboards interactivos que faciliten la exploración por parte de investigadores y responsables de políticas públicas. Así también, aunque no menos relevante, es el costo de la implementación del presente trabajo, como se puede observar el costo de obtención de la información es “cero”, pues son datos disponibles en los sitios web de cada diario que se extrae usando el código *web scraping* propuesto.

En conclusión, se pudo cumplir con los objetivos planteados, construyendo un proceso de recolección, procesamiento y consolidación de noticias que sienta bases sólidas para análisis posteriores. Esta sección deja planteadas no sólo las fortalezas y limitaciones del trabajo realizado, sino también los retos y caminos a seguir en la búsqueda de un entendimiento más profundo de los robos en contextos similares.

5.3. Trabajos a futuro

Como proyección de este trabajo, se propone ampliar el de análisis incorporando un mayor número de diarios tanto de Lima Metropolitana como de Provincias del Perú, así como, a largo plazo, integrar nuevos medios de comunicación de otros países hispanohablantes. Esto permitiría construir una base más consolidada y representativa en contraste al discurso mediático sobre los robos, fortaleciendo el carácter comparativo del trabajo.

De igual forma, se plantea continuar con el análisis automatizado de noticias mediante la aplicación de técnicas avanzadas de procesamiento del lenguaje natural y visualizaciones interactivas, con el propósito de generar nuevos hallazgos y patrones complejos que contribuyan a una comprensión más amplia y contextualizada del fenómeno en diferentes entornos socioculturales. Este esfuerzo permitirá, a mediano y largo plazo, consolidar un observatorio mediático con enfoque territorial, que favorezca la investigación aplicada y la formulación de políticas públicas basadas en evidencia.

Así también, se sugiere automatizar el proceso de web scraping, pues la extracción se implementó mediante consultas por URL por fechas específicas, lo que condujo un proceso secuencial y prolongado. Una propuesta consistiría en desarrollar un script automatizado que recorra rangos completos de fechas, administre errores de conexión, revise si hay páginas sin contenido, y consolide automáticamente los resultados en una base única. Esto ayudaría mucho en reducir tiempos de extracción, optimizar la reproducibilidad del proceso y proveer la actualización constante del conjunto de noticias.

Otro trabajo futuro podría ser la aplicación de técnicas avanzadas de Procesamiento de Lenguaje Natural (PLN), el cual ayudaría a optimizar significativamente el análisis contextual de las noticias, evitando así las limitaciones de basarse en palabras clave. Así también, cabe sugerir la aplicación de análisis de sentimientos, el cual ayudaría a identificar la carga emocional y perceptiva existente en las noticias asociadas con robos, contribuyendo así con una dimensión adicional al análisis textual tradicional. Es decir, contribuyendo con un análisis más integral del contexto delictivo desde una perspectiva comunicacional y social.

Asimismo, cabe sugerir la importancia de la integración de datos oficiales de criminalidad de fuentes de entidades como la Policía Nacional del Perú, el Ministerio del Interior o el INEI (Instituto Nacional de Estadística e Informática – INEI) ayudaría a

integrar y contrastar la data recolectada de noticias digitales. Esto permitiría fortalecer la validez y consistencia del análisis espacial estudiado, ayudando a confrontar patrones mediáticos con registros institucionales y disminuyendo posibles sesgos provenientes de la cobertura periodística, principalmente en distritos con menor visibilidad informativa.

5.4. Contribución de la investigación

Como complemento, la unificación del análisis espacial con los resultados de la matriz de contingencia ayuda a determinar no solo dónde suceden los robos, sino también qué clase de robos prevalecen en cada distrito, bajo un análisis profundo de cada uno de los términos asociados a robo. Esta asociación entre dimensión espacial y tipológica fortifica el entendimiento del hecho delincuencial, facilitando la determinación de patrones más complejos.

Así también, el análisis espacial propone que los robos no se asignan de manera aleatoria en una región o zona, sino que corresponden a lógicas urbanas particulares, tales como la densidad poblacional, la existencia de centros comerciales, lugares de tránsito o de alto tráfico peatonal. Esto fortifica el enfoque donde el evento está condicionado por factores del ambiente urbano.

Capítulo 6: Referencias

Blei, D. M. (2012). Probabilistic topic models. *Communications of the ACM*, 55(4), 77–84. <https://doi.org/10.1145/2133806.2133826>

Chainey, S., Tompson, L., & Uhlig, S. (2008). The utility of hotspot mapping for predicting spatial patterns of crime. *Security Journal*, 21(1–2), 4–28. <https://doi.org/10.1057/palgrave.sj.8350066>

Chen, H., Chung, W., & Xu, J. (2004). Crime data mining: A general framework and some examples. *Computer*, 37(4), 50–56. <https://doi.org/10.1109/MC.2004.1297301>

Espinoza-Ramírez, A., Nakano, M., Sánchez-Pérez, G., & Arista-Jalife, A. (2018). Sistemas de información geográfica y su análisis aplicado en zonas de delincuencia en la Ciudad de México. *Información Tecnológica*, 29(5), 235–246. <https://doi.org/10.4067/S0718-07642018000500235>

Everitt, B. S., Landau, S., Leese, M., & Stahl, D. (2011). *Cluster analysis* (5th ed.). Wiley.

Fayyad, U. M., Piatetsky-Shapiro, G., & Smyth, P. (1996). From data mining to knowledge discovery in databases. *AI Magazine*, 17(3), 37–54. <https://doi.org/10.1609/aimag.v17i3.1230>

Freedman, D., Pisani, R., & Purves, R. (2007). *Statistics* (4th ed.). W. W. Norton & Company.

GADM. (2024). GADM database of Global Administrative Areas. <https://gadm.org/>

Giraldo, R. (2002). *Análisis estadístico de datos textuales*. Bogotá: Universidad Nacional de Colombia.

Greenacre, M. (2017). *Correspondence analysis in practice* (3rd ed.). CRC Press.

Hackeloeer, A., Klasing, K., Krisp, J. M., & Meng, L. (2014). Georeferencing: A review of methods and applications. *International Journal of Geographical Information Science*, 28(8), 1501–1528. <https://doi.org/10.1080/19475683.2013.868826>

Han, J., Kamber, M., & Pei, J. (2012). *Data mining: Concepts and techniques* (3rd ed.). Morgan Kaufmann.

Harries, K. (2001). *Crime mapping and spatial analysis*. National Institute of Justice.

Hearst, M. A. (1999). Untangling text data mining. In *Proceedings of the 37th Annual Meeting of the Association for Computational Linguistics* (pp. 3–10). Association for Computational Linguistics. <https://doi.org/10.3115/1034678.1034679>

Hernández Salazar, L. (2020). *Métricas multivariantes textuales georreferenciadas: Caso aplicado al Estado de Veracruz 2020* [Tesis de maestría, Universidad Autónoma de Guerrero, Facultad de Matemáticas, Maestría en Métodos Estadísticos Aplicados].

Hill, M. (2006). *Geographic information systems: Concepts and applications*. CRC Press.

Instituto Nacional de Estadística e Informática (INEI). (2024). Victimización en el Perú 2024: Encuesta Nacional de Programas Presupuestales. INEI.

International Organization for Standardization. (2003). *ISO 19112:2003 geographic information — Spatial referencing by geographic identifiers*. ISO.

International Organization for Standardization. (2007). *ISO 19111:2007 geographic information — Spatial referencing by coordinates*. ISO.

Jurafsky, D., & Martin, J. H. (2026). *Speech and language processing* (3rd ed., draft). <https://web.stanford.edu/~jurafsky/slp3/>

Kantardzic, M. (2011). *Data mining: Concepts, models, methods, and algorithms* (2nd ed.). Springer.

Kinne, J., & Axenbeck, J. (2020). Web mining for innovation ecosystem mapping: A framework and a large-scale pilot study. *Scientometrics*, 125(4), 2011–2041. <https://doi.org/10.1007/s11192-020-03726-9>

Leidner, J. L. (2008). *Toponym resolution in text: Annotation, evaluation and applications of spatial grounding of place names*. Springer.

Liu, B. (2012). *Sentiment analysis and opinion mining*. Morgan & Claypool Publishers. <https://doi.org/10.2200/S00416ED1V01Y201204HLT016>

Liu, X., Andris, C., & Ratti, C. (2011). Uncovering cabdrivers' behavior patterns from their digital traces. *Computers, Environment and Urban Systems*, 34(6), 541–548. <https://doi.org/10.1016/j.compenvurbsys.2010.07.003>

Mitchell, R. (2018). *Web scraping with Python: Collecting more data from the modern web* (2nd ed.). O'Reilly Media.

Moreno Jiménez, A., & Grijalva Eternod, A. E. (2022). Alternativas para la medición de la delincuencia urbana y la identificación de zonas criminógenas: Nuevos indicadores

basados en la presencia de población. *Estudios Geográficos*, 83(293), e121. <https://doi.org/10.3989/estgeogr.2022127.127>

Nadeau, D., & Sekine, S. (2007). A survey of named entity recognition and classification. *Linguisticae Investigationes*, 30(1), 3–26. <https://doi.org/10.1075/li.30.1.03nad>

Perú. Decreto Legislativo N.º 635, Código Penal. (1991). *Diario Oficial El Peruano*. <https://www.gob.pe/institucion/indecopi/normas-legales/5582266-635>

Project Guru. (s. f.). *Text mining: Analyzing unstructured data*. Recuperado el 10 de febrero de 2026, de <https://www.projectguru.in/text-mining-analyzing-unstructured-data/>

Real Academia Española. (s. f.). *Robo*. En *Diccionario de la lengua española* (23.ª ed.). Recuperado el 11 de enero de 2026, de <https://dle.rae.es/robo>

Ricci, F., Rokach, L., & Shapira, B. (Eds.). (2011). *Recommender systems handbook*. Springer. <https://doi.org/10.1007/978-0-387-85820-3>

Salton, G., & Buckley, C. (1988). Term-weighting approaches in automatic text retrieval. *Information Processing & Management*, 24(5), 513–523. [https://doi.org/10.1016/0306-4573\(88\)90021-0](https://doi.org/10.1016/0306-4573(88)90021-0)

Sarawagi, S. (2008). Information extraction. *Foundations and Trends® in Databases*, 1(3), 261–377. <https://doi.org/10.1561/19000000003>

Tao, L., Xie, Z., Xu, D., Ma, K., Qiu, Q., Pan, S., & Huang, B. (2022). Geographic named entity recognition by employing natural language processing and an improved BERT model. *ISPRS International Journal of Geo-Information*, 11(12), 598. <https://doi.org/10.3390/ijgi11120598>

Villa Monte, A. (2023). *Minería de datos: Tema 2: Catálogo de recursos técnicos* [Diapositivas en PDF]. Universidad Internacional de Valencia.

Wang, X., Gerber, M. S., & Brown, D. E. (2012). Automatic crime prediction using events extracted from Twitter posts. In *Social Computing, Behavioral-Cultural Modeling and Prediction* (pp. 231–238). Springer. https://doi.org/10.1007/978-3-642-29047-3_28

Capítulo 7: Anexos

Anexo I: Repositorio de código y archivos

Link Github:

<https://github.com/AlexanderFernandezE/TFM-VIU-Alexander-Fernandez>

Anexo II: Trazabilidad de uso de IA

Herramienta IA	Mes de consulta	Sección	Prompts Utilizados
ChatGPT	Febrero 2026	Estado del arte	En una referencia por ejemplo al colocar: Fayyad et al. (1996) ¿Qué significa et al.?
ChatGPT	Febrero 2026	Estado del arte	En relación a la elaboración de una TFM llamada "Minería de textos georreferenciados aplicada al contexto de robos en Lima, Perú" Citar referencias papers asociadas a la TFM
ChatGPT	Febrero 2026	Estado del arte	En el texto de la TFM, al colocar: Adaptado de ... ¿cómo debo colocarlo?
ChatGPT	Febrero 2026	Hallazgos encontrados	Si lo adjunto es una base de datos de noticias, dame una tabla resumen de cantidad de noticias por año y por diario.
ChatGPT	Febrero 2026	Referencias	En relación a bibliografía en una TFM, ordena este listado como debería estar correctamente, y también coloca en cursiva si corresponde.